

S02 · PART 01 · 엑셀 · 난이도 1

좋은 데이터의 모양: tidy 데이터 와 척도

엑셀 표가 피벗테이블, AI 분석, 파이썬, BI 도구에서 안정적으로 작동하려면 어떤 모양이어야 하는지 익힌다.

오늘 끝나면 할 수 있는 것

- 01 분석하기 좋은 표의 기본 모양을 설명한다.
- 02 한 셀 한 값, 한 행 한 관찰, 한 열 한 변수의 의미를 엑셀 표에서 찾는다.
- 03 병합셀, 빈 셀, 표기 혼재, 숫자와 문자의 혼합이 분석을 방해하는 이유를 이해한다.
- 04 컬럼별로 범주형, 순서형, 수치형, 날짜형, 논리형 척도를 구분한다.
- 05 dirty 데이터에서 tidy 원칙을 어기는 지점을 찾아 교정 방향을 말한다.

분석용 표는 보기 좋은 보고서와 다르다

회의 자료로 읽기 좋은 표와 분석 도구가 좋아하는 표는 다르다. 분석용 표는 장식보다 규칙이 중요하다.

- 제목, 병합셀, 중간 소제, 설명이 많은 표는 사람이 읽기에는 편하지만 분석에는 걸림돌이 된다.
- 카페 매출 데이터에서는 주문 한 건이 한 행이다.
- `date`, `store`, `item`, `qty`, `amount`처럼 각 열은 주문을 설명하는 한 가지 속성만 담는다.

tidy 데이터는 세 가지 규칙으로 기억한다

tidy 데이터는 분석하기 좋은 표의 기본형이다. 입문 단계에서는 다음 세 문장으로 충분하다.

- **한 행은 한 관찰이다.** 한 줄은 주문 한 건, 고객 한 명, 직원 한 명처럼 같은 단위에 있어야 한다.
- **한 열은 한 변수다.** 한 열에는 날짜, 지점, 상품명, 수량처럼 하나의 의미만 있어야 한다.
- **한 셀은 한 값이다.** 셀 하나에는 하나의 값만 들어가야 한다.

병합셀과 섞인 값은 분석 구조를 무너뜨린다

병합셀은 사람 눈에는 같은 그룹처럼 보이지만, 컴퓨터는 첫 셀만 값이 있고 나머지는 빈 칸으로 처리하는 경우가 많다.

- `4,500원`은 사람에게는 친절하지만 숫자 4500이 아니라 글자가 섞인 값일 수 있다.
- `강남점`과 `강남 점`은 사람에게는 같은 지점이지만 피벗테이블은 다른 지점으로 볼 수 있다.
- 분석용 원본 표에는 병합셀을 피하고, 값은 계산 가능한 형태로 저장한다.

이번 차시의 데이터 규모

파일	행	열	시트 또는 파일
`cafe_sales_clean.csv`	10,424	12	CSV
`cafe_sales_dirty.csv`	10,439	12	CSV
`cafe_sales_clean.xlsx`	10,424	12	`sales`
`cafe_sales_dirty.xlsx`	10,439	12	`sales`

두 파일의 컬럼은 `order\_id`, `date`, `weekday`, `hour`, `store`, `category`,
`item`, `unit\_price`, `qty`, `amount`, `payment`, `member`로 같다.

dirty 데이터에서 확인한 대표 문제

컬럼	발견한 문제	확인한 개수	교정 방향
`order_id`	같은 주문번호가 반복됨	중복 주문번호 15건	실제 중복이면 한 건만 남기고, 재주문이면 별도 주문번호를 부여한다.
전체 행	완전히 동일한 행이 있음	13행	중복 제거 전후 행수와 매출 합계를 비교한다.
`payment`	결제수단 결측	313행	원자료 확인, 불명 처리, 분석 제외 중 선택한다.
`member`	회원 여부 결측	209행	원자료 확인, 불명 처리, 분석 제외 중 선택한다.
`unit_price`	숫자와 문자가 섞임	157행	`원`과 심표 제거 후 숫자형으로 변환한다.
`qty`	비현실적 수량	999가 2행	원자료 확인 후 수정 또는 제외한다.

척도는 분석 방법을 고르는 기준이다

컬럼을 볼 때는 값의 모양뿐 아니라 이 값으로 무엇을 할 수 있는지를 함께 본다. 이것이 척도 구분이다.

- 범주형은 지점, 상품명, 결제수단처럼 그룹을 구분한다.
- 수치형은 수량, 단가, 주문금액처럼 합계와 평균을 계산할 수 있다.
- 날짜형은 주문일처럼 시간의 흐름을 나타낸다.
- 논리형은 회원 여부처럼 참과 거짓 또는 예와 아니오를 나타낸다.
- 식별자는 주문번호처럼 각 행을 구분하는 이름표다.

clean 데이터의 컬럼별 척도

컬럼	척도	가능한 분석	주의할 점
`order_id`	식별자	중복 확인, 주문 추적	숫자로 보여도 평균이나 합계는 의미 없음
`date`	날짜형	일별, 월별, 요일별 추세	날짜 형식이 섞이면 먼저 통일 필요
`weekday`	순서가 있는 범주형	요일별 매출, 주중·주말 비교	평균 요일 계산은 의미 없음
`hour`	시간형 수치	시간대별 주문 수, 피크 시간 확인	8~21시 범위의 시간대로 해석
`store`	범주형	지점별 매출, 지점별 주문 수	`강남점`과 `강남 점` 같은 표기 혼재 주의
`amount`	수치형	총매출, 평균 주문금액	음수 금액 또는 단가×수량 불일치 확인 필요
`member`	논리형	회원 여부별 매출, 회원 비율	결측값 처리 기준 필요

`weekday`는 범주형으로 볼 수 있고, 월요일부터 일요일까지 순서가 있는 범주로도 다룰 수 있다. 다만 평균을 내는 숫자는 아니다.

오늘의 미션

미션 1. 컬럼별 척도 분류

`cafe\_sales\_clean.xlsx`의 12개 컬럼을 척도별로 분류한 표를 작성한다. 가능한 분석과 주의할 점을 함께 적는다.

미션 2. dirty 데이터 문제 찾기

`cafe\_sales\_dirty.xlsx`에서 발견한 문제 5개 이상과 교정 방향을 작성한다. 표기 혼재, 결측, 날짜 형식 혼합, 숫자와 문자 혼합, 이상치를 확인한다.

정리

- 분석용 표는 예쁜 표가 아니라 규칙적인 표여야 한다.
- tidy 데이터는 한 행 한 관찰, 한 열 한 변수, 한 셀 한 값이라는 구조를 지킨다.
- 숫자로 보여도 `order\_id`처럼 계산 대상이 아닌 식별자가 있다.
- 표기 혼재와 문자 섞인 숫자는 피벗테이블 결과를 틀어지게 만들 수 있다.

다음 차시에서는 피벗테이블로 지점별, 카테고리별, 요일별 매출 질문에 답한다.