

S02 · PART 01 · 엑셀 · 난이도 1

tidy 데이터와 척도

예쁜 표가 아니라 분석 도구가 읽을 규칙을 본다.

오늘 끝나면 할 수 있는 것

- 01 한 행 한 관찰, 한 열 한 변수를 설명한다
- 02 dirty 표의 문제와 교정 방향을 찾는다
- 03 컬럼별 척도를 분석 방법과 연결한다

엑셀 표를 분석 표로 본다



엑셀에서도 원본 표의 규칙이 분석을 정한다.

엑셀 표를 볼 때는 색이나 테두리보다 먼저 규칙을 봅니다. 이 그림은 엑셀 화면 자체보다, 표가 분석 도구에게 어떻게 읽히는지를 보자는 뜻입니다.

한 줄을 가로로 읽으면 주문 한 건이 설명되어야 하고, 한 열을 세로로 읽으면 날짜, 지점, 상품명, 수량처럼 한 가지 의미만 이어져야 합니다. 키를 질 때 키만 적고 몸무게는 다른 칸에 적듯이, 값마다 자기 자리가 있어야 합니다.

사람에게 보기 좋은 표와 분석하기 좋은 표는 다를 수 있습니다. 병합셀이나 소계 행이 많으면 보고서로는 편해도, 피벗테이블이나 분석 도구는 빈칸과 다른 행으로 읽을 수 있습니다. 그래서 원본 표에서는 꾸밈보다 규칙을 먼저 확인해 보세요.

tidy 데이터의 세 규칙

규칙	뜻	깨지는 예
한 행 한 관찰	주문 한 건 한 줄	소계 행
한 열 한 변수	한 열 한 의미	상품/수량 혼합
한 셀 한 값	셀 하나 값 하나	4,500원

병합셀은 빈 값과 구조 오류를 만들 수 있다.

tidy 데이터는 분석하기 좋은 표의 기본 모양입니다. 표에 있는 세 규칙은 모두 같은 말을 다른 방향에서 보는 것입니다. 한 행은 무엇 한 건인지, 한 열은 어떤 의미인지, 한 셀에는 값이 하나만 들어 있는지를 확인합니다.


'한 행 한 관찰'은 주문 한 건이 한 줄이어야 한다는 뜻입니다. 중간에 소계 행이 끼면 그 줄은 주문이 아니라 계산 결과라서, 주문 목록에 다른 종류의 물건이 섞인 것처럼 됩니다.

tidy 데이터의 세 규칙 이어서

열과 셀의 규칙은 값의 자리를 나눠 보라는 말입니다. 상품명과 수량이 한 열에 같이 있거나, 4,500원처럼 숫자와 단위가 한 셀에 붙어 있으면 계산 전에 다시 분리해야 합니다. 분석용 표에서는 값은 값대로 두고, 단위 표시는 서식으로 처리하는 편이 안전합니다.

병합셀도 조심해야 합니다. 사람 눈에는 같은 묶음으로 보이지만, 컴퓨터는 첫 칸만 값이 있고 나머지는 빈칸이라고 볼 수 있습니다. 사전에서 단어를 찾듯이, 각 칸마다 바로 읽을 수 있는 값이 들어 있어야 합니다.

두 표의 행수가 다릅니다



결과


dirty는 clean보다 **15행** 많아 중복 확인이 필요하다.

이 비교 그림은 정리된 표와 연습용 문제 표의 크기를 나란히 보여줍니다. 왼쪽 정리된 표는 10424행, 오른쪽 연습용 문제 표는 10439행이고, 열은 둘 다 12개입니다.

눈여겨볼 곳은 행 숫자입니다. 열 수가 12로 같다는 말은 담고 있는 항목 종류는 같다는 뜻이고, 행 수가 10439로 늘었다는 말은 주문 줄이 더 많아졌다는 뜻입니다.

차이는 15행입니다. 같은 주문이 반복되었을 수도 있고, 실제로 추가된 주문일 수도 있습니다. 분석에서는 이 15행을 그냥 넘기지 말고, 주문번호를 열쇠처럼 잡고 같은 주문이 다시 나온 것인지 확인해야 합니다.

중복은 두 기준으로 봅니다



결과


중복 주문번호와 완전 동일 행은 따로 판단한다.

이 그림은 중복을 한 가지로만 보면 안 된다는 점을 보여줍니다. 왼쪽은 주문번호가 반복된 경우이고, 오른쪽은 모든 칸의 값이 완전히 같은 행입니다.

왼쪽의 중복 주문번호 15건은 같은 주문번호가 다시 등장했다는 뜻입니다. 주문번호는 택배 송장번호 처럼 한 주문을 추적하는 이름표이므로, 같은 번호가 여러 번 나오면 주문 건수 계산이 흔들릴 수 있습니다.

오른쪽의 완전 동일 중복 13행은 행 전체가 똑같은 경우입니다. 주문번호는 같지만 다른 칸이 조금 다른 행도 있을 수 있으니, 주문번호 기준 15건과 완전 동일 행 13행을 따로 봐야 합니다. 삭제하기 전에는 무엇이 같은지, 무엇이 다른지 비교해 보세요.

큰 문제부터 먼저 봅니다



결과

결측·공백·표기 혼재가 먼저 살필 큰 문제다.

이 막대그래프는 연습용 문제 표에서 많이 나온 오류 유형을 큰 것부터 보여줍니다. 막대가 길수록 그런 문제가 들어 있는 행이 많다는 뜻입니다.


가장 먼저 볼 곳은 313행으로 표시된 결제수단 빈칸과 카테고리 공백입니다. 결측은 값이 비어 있다는 말이고, 공백은 값 앞뒤에 빈칸이 붙어 사람 눈에는 같아 보여도 컴퓨터가 다르게 읽을 수 있는 상태입니다. 강남 점처럼 지점명이 띄어 써진 경우도 310행으로 큼니다.

큰 문제부터 먼저 봅니다 이어서

그다음에는 회원 여부 빈칸 209행, 날짜에 /가 섞인 형식 206행, 단가에 문자가 섞인 행 157행을 봅니다. 이 문제들은 행마다 작아 보여도 그룹별 매출, 날짜별 추세, 평균 단가 계산을 틀어지게 만들 수 있습니다.

처음부터 모든 문제를 한꺼번에 고치려고 하기보다, 막대가 긴 항목부터 확인해 보세요. 저울에 큰 짐부터 올려 무게를 가늠하듯이, 분석 결과를 많이 흔드는 문제부터 잡는 것이 좋습니다.

날짜 표기가 두 가지 더 섞입니다



결과

월별·요일별 분석 전에 하나의 날짜형으로 통일한다.

이 막대그래프는 날짜 열 안에 표기 방식이 얼마나 섞였는지를 보여줍니다. 날짜는 모두 같은 날짜처럼 보여도, 쓰는 방식이 다르면 분석 도구가 서로 다른 글자로 읽을 수 있습니다.


왼쪽 막대 YYYY/MM/DD는 206행입니다. 예를 들어 연-월-일 사이에 빗금이 들어간 방식입니다. 오른쪽 MM-DD-YYYY는 104행으로, 월-일-연도 순서로 적힌 방식입니다.

날짜 표기가 두 가지 더 섞입니다

이어서

월별 매출이나 요일별 주문을 보려면 날짜가 하나의 날짜형으로 통일되어 있어야 합니다. 달력에서 날짜를 고르듯이 모두 같은 규칙으로 바꿔 놓아야, 3월 매출이나 일요일 주문 같은 질문에 안정적으로 답할 수 있습니다.

아메리카노가 여러 이름이 된다



결과


같은 상품이 다른 그룹으로 집계될 수 있다.

이 막대그래프는 같은 아메리카노가 여러 이름으로 흩어진 상황을 보여줍니다. 막대 세 개는 모두 같은 상품으로 보아야 할 가능성이 큰데, 표 안에서는 서로 다른 이름으로 들어가 있습니다.

아메리카는 37행, Americano는 36행, 아메리카노는 33행입니다. 사람은 문맥으로 같은 상품이라고 알아차리지만, 엑셀 피벗테이블은 글자가 다르면 다른 상품으로 묶을 수 있습니다.

이 상태로 상품별 매출을 계산하면 아메리카노 매출이 여러 줄로 갈라집니다. 사전에서 표준 표기를 하나 정하듯이, 같은 상품은 한 이름으로 통일한 뒤 집계해 보세요.

숫자 열에 문자가 섞인다



결과


가격 열에는 가격만 있어야 합계와 평균을 낼 수 있다.

이 변환 그림은 단가 열을 계산 가능한 숫자로 바꾸는 과정을 보여줍니다. 왼쪽은 단가 값에 원이나 십표가 섞인 상태이고, 오른쪽은 계산할 수 있는 숫자형으로 정리한 상태입니다.

왼쪽에는 원·십표가 들어간 단가가 157행 있습니다. 4,500원은 사람에게는 읽기 쉽지만, 컴퓨터에게는 숫자 4500이 아니라 글자가 섞인 값으로 보일 수 있습니다.

오른쪽처럼 원과 십표를 제거하면 값이 4500처럼 숫자로 남습니다. 가격 열에는 가격만 있어야 합계와 평균을 낼 수 있습니다. 단위인 원 표시는 값 안에 넣기보다 엑셀 서식으로 붙이는 편이 좋습니다.

작은 오류가 계산을 흔든다



결과

행수는 적어도 총매출과 평균을 왜곡할 수 있다.

이 막대그래프는 행 수는 적지만 계산을 크게 흔들 수 있는 오류를 보여줍니다. 앞의 313행짜리 문제 보다 작아 보이지만, 매출 합계와 평균에는 더 날카롭게 영향을 줄 수 있습니다.

금액 불일치는 3행입니다. 단가와 수량을 곱한 값이 주문금액과 맞지 않는다는 뜻입니다. qty=999는 2행인데, 카페 주문에서 수량 999는 실제 주문이라기보다 입력 실수일 가능성이 높습니다.

작은 오류가 계산을 흔든다 이어서

amount 음수는 1행입니다. 환불처럼 별도 설명이 있으면 의미가 있지만, 그냥 매출 표에
섞여 있다면 확인이 필요합니다. 이런 값은 작은 돌멩이 같아 보여도 평균이라는 저울 위
에서는 전체 무게를 크게 바꿀 수 있습니다.

척도는 분석 방법을 정합니다

값의 모양보다 이 값으로 무엇을 할 수 있는지 먼저 본다.

- 식별자: order_id
- 날짜·시간: date, hour
- 범주: store, item, payment
- 수치: unit_price, qty, amount
- 논리: member

척도는 각 열의 값으로 무엇을 할 수 있는지 정하는 기준입니다. 이름표처럼 구분만 하는 값인지, 더하고 평균을 낼 수 있는 값인지, 날짜처럼 시간 순서로 볼 값인지 나눠 보는 것입니다.

식별자인 order_id는 주문을 찾는 이름표입니다. 숫자처럼 보여도 평균 주문번호는 의미가 없습니다. store, item, payment는 범주라서 지점별, 상품별, 결제수단별로 묶어 세거나 합계를 내기에 좋습니다.

척도는 분석 방법을 정합니다

이어서

unit_price, qty, amount는 수치입니다. 이 값들은 더하거나 평균을 낼 수 있습니다.
date와 hour는 시간 흐름을 보는 데 쓰고, member는 회원인지 아닌지처럼 참과 거짓으로 나눠 비율이나 비교를 할 때 씁니다.

표를 분석하기 전에는 각 열을 한 번씩 손가락으로 짚어 보듯 확인해 보세요. 이 열은 그룹으로 묶을 열인지, 계산할 열인지, 시간을 따라 볼 열인지 정하면 피벗테이블에서 어디에 넣어야 할지도 훨씬 분명해집니다.

오늘의 미션

미션 1. 척도 분류

clean 12개 컬럼을 척도별로 분류한다.

미션 2. 문제와 교정

dirty 문제 5개 이상과 교정 방향을 쓴다.

정리

- tidy 표는 한 행·한 열·한 셀의 단위를 지킨다.
- dirty 문제는 결측, 표기, 형식, 이상치로 나눠 본다.
- 척도는 집계·평균·비율·추세 선택의 기준이다.

다음 차시 — 피벗테이블로 지점별·카테고리별·요일별 매출을 답한다.