

S05 · PART 02 · 통계 · 난이도 2

중심·산포·분포·박스플롯

숫자 열 하나에서 대표값, 퍼짐, 이상치, 보통의 값을 함께 읽는 법을
다룬다.

오늘 끝나면 할 수 있는 것

- 01 평균, 중앙값, 최빈값의 차이를 설명한다.
- 02 범위와 표준편차가 값의 퍼짐을 나타낸다는 점을 이해한다.
- 03 사분위수, IQR, 이상치의 기본 의미를 말한다.
- 04 박스플롯을 보고 그룹별 분포의 위치, 퍼짐, 이상치를 비교한다.
- 05 평균이 왜곡될 수 있는 상황을 찾아 중앙값과 함께 해석한다.

핵심 개념 1

평균은 중요하지만 혼자서는 부족하다

평균은 전체적인 수준을 빠르게 알려 주지만, 보통의 값과 값의 퍼짐, 극단적으로 큰 값의 존재까지 설명하지는 못한다.

- 핵심 질문은 이 숫자들의 대표값이 무엇인지 묻는 데서 시작한다.
- 값들이 얼마나 흩어져 있는지 확인해야 한다.
- 평균을 그대로 믿어도 되는지 중앙값과 산포로 함께 확인해야 한다.

대표값 세 가지는 서로 다른 질문에 답한다

대표값은 숫자 목록을 한 숫자로 요약하려는 시도다. 평균, 중앙값, 최빈값은 같은 데이터틀 보더라도 서로 다른 관점을 제공한다.

- **평균:** 전체 합계를 개수로 나눈 값이며 모든 값을 반영하지만 극단값에 민감하다.
- **중앙값:** 값을 줄 세웠을 때 가운데 있는 값이며 보통의 값을 설명할 때 유용하다.
- **최빈값:** 가장 많이 반복된 값이며 가격, 등급, 점수처럼 같은 값이 반복되는 데이터에서 의미가 있다.

평균과 중앙값의 차이는 분포의 힌트다

입문 단계에서는 평균과 중앙값을 함께 보는 습관이 중요하다.

- 평균과 중앙값이 비슷하면 값들이 비교적 균형 있게 퍼져 있을 가능성이 있다.
- 평균이 중앙값보다 크면 큰 값 몇 개가 평균을 끌어올렸을 가능성이 있다.
- 평균이 중앙값보다 작으면 작은 값들이 평균을 끌어내렸을 가능성이 있다.

산포는 중심만으로 보이지 않는 차이를 보여 준다

두 부서의 평균 연봉이 비슷해도 한 부서는 모두 비슷하게 받고, 다른 부서는 낮은 연봉과 높은 연봉이 섞여 있을 수 있다. 이 차이를 보는 것이 산포다.

- 범위는 최댓값에서 최솟값을 뺀 값이다.
- 표준편차가 작으면 값들이 평균 근처에 모여 있다.
- 표준편차가 크면 값들이 평균에서 넓게 퍼져 있다.

박스플롯은 분포를 한 장으로 접어 보여 준다

요소	의미
박스의 아래쪽	1사분위수, 하위 25% 지점
박스 안의 선	중앙값
박스의 위쪽	3사분위수, 상위 25% 지점
박스 높이	가운데 50% 값의 퍼짐
수염	일반적인 최솟값과 최댓값 범위
따로 찍힌 점	이상치 후보

박스플롯은 평균 하나보다 많은 정보를 주며, 그룹별 위치와 퍼짐과 이상치 후보를 함께 비교하게 한다.

엑셀에서는 계산과 해석을 함께 진행한다

하고 싶은 일	엑셀 함수 또는 기능	이번 차시에서의 사용
평균 구하기	AVERAGE, AVERAGEIF	부서별 평균 연봉
중앙값 구하기	MEDIAN	부서별 중앙 연봉
최빈값 구하기	MODE.SNGL	가장 자주 나오는 연봉 또는 주문금액
최솟값·최댓값	MINIFS, MAXIFS	부서별 연봉 범위
표준편차	STDEV.S	부서별 연봉 산포
사분위수	QUARTILE.INC	박스플롯을 해석하기 위한 기준
분포 시각화	상자 수염 그림	부서별 연봉 분포 비교

평균만 보고 결론을 내리면 보통의 값, 값의 퍼짐, 이상치 여부를 놓칠 수 있다.

HR 연봉 요약은 부서 간 위치와 퍼짐을 드러낸다

부서	직원 수	평균	중앙값	표준편차	이상치 수
개발본부	370	74,190,541	73,950,000	8,094,278	6
데이터전략팀	250	68,902,000	68,450,000	8,955,824	2
영업본부	240	63,087,500	62,700,000	8,070,936	3
인사총무팀	180	59,414,444	59,100,000	8,771,463	3
고객운영팀	160	53,445,625	53,300,000	8,456,056	0

개발본부는 평균과 중앙값이 가장 높고, 고객운영팀은 평균과 중앙값이 가장 낮다. 데이터전략팀은 표준편차가 가장 커서 부서 안 연봉의 퍼짐이 비교적 크다.

카페 주문에서는 평균이 보통 주문금액을 과장할 수 있다

상품	주문 건수	평균	중앙값	평균 - 중앙값
치즈케이크	633	10,740.92	6,500	4,240.92
레몬에이드	644	9,940.99	6,000	3,940.99
크로플	609	9,112.48	5,500	3,612.48
바닐라라떼	1,151	9,098.18	5,500	3,598.18
복숭아아이스티	652	9,051.38	5,500	3,551.38

치즈케이크는 1개 주문 331건, 2개 주문 191건, 3개 주문 111건이어서 평균이 10,740.92원까지 올라간다.

오늘의 미션

따라하기 1. 부서별 연봉 요약표 만들기

hr_employees_clean.xlsx의 employees 시트에서 부서별 직원 수, 평균, 중앙값, 최빈값, 범위, 표준편차, 사분위수, IQR, 이상치 수를 계산한다.

따라하기 2. 부서별 연봉 박스플롯 만들기

dept_boxplot 시트에 부서별 salary를 열로 펼치고 상자 수염 그림으로 부서별 연봉 분포를 비교한다.

직접 해보기. 평균 왜곡 사례 찾기

cafe_sales_clean.xlsx의 sales 시트에서 상품별 주문금액 amount의 평균과 중앙값을 비교하고 mean_minus_median이 가장 큰 상품을 해석한다.

정리

- 평균은 전체 수준을 빠르게 짚어 주지만, 보통의 위치와 극단값 여부까지 설명하지는 못한다.
- 중앙값, 최빈값, 범위, 표준편차, 박스플롯을 함께 보면 중심과 산포를 함께 말할 수 있다.
- 치즈케이크 사례처럼 평균이 중앙값보다 높을 때는 주문 수량 같은 원인을 확인해야 한다.

다음 차시: S06에서는 상관 vs 인과, 심슨의 역설을 다루고 두 수치형 변수가 함께 움직이는 사실과 원인 주장을 구분한다.