

S05 · PART 02 · 통계 · 난이도 2

중심·산포·분포·박스플롯

평균만 보지 않고 보통값, 퍼짐, 이상치도 함께 읽는다.

학습 후 할 수 있는 것

- 01 평균·중앙값·최빈값을 구분한다
- 02 범위와 표준편차로 퍼짐을 읽는다
- 03 박스플롯으로 이상치 후보를 찾는다
- 04 평균이 왜곡되는 사례를 설명한다


숫자 한 열을 읽는 지도

PART 02 · 통계

분포와 상관을 읽는다


분포 · 히스토그램

빈도 · 정규곡선




분포 · 박스플롯

사분위수 · 이상치



상관관계

molit 실거래가 · 전용면적 → 거래금액



상관은 인과가 아니다 — 심슨의 역설 주의

hr_employees 데이터에서 전체 경향과 그룹별 경향이 반대로 나타나는 사례가 확인됨

데이터셋 · molit 실거래가 ($r = 0.806$) · hr_employees (심슨의 역설)

STATISTICS

중심, 산포, 분포를 함께 보면 평균의 한계가 보인다.


핵심 개념 1

대표값마다 역할이 다르다

평균은 전체 수준, 중앙값은 보통의 위치, 최빈값은 가장 자주 나온 값을 나타낸다.

- 평균: 전체 합계 $\div$ 개수
- 중앙값: 순서대로 세웠을 때 가운데
- 최빈값: 가장 자주 나온 값
- 평균이 높으면 큰 값이 끌어올렸을 수 있다


평균 연봉은 개발본부가 높다



결과

개발본부 평균이 가장 높고 고객운영팀이 가장 낮다.


중앙값도 같은 순서다



결과

보통 위치로 보아도 개발본부가 높고 고객운영팀이 낮다.


퍼짐은 데이터전략팀이 크다



결과

데이터전략팀은 부서 내 연봉 퍼짐이 가장 크다.

이상치 후보는 개발본부가 많다



결과


개발본부에는 위쪽 이상치 후보가 있고 고객운영팀에는 없다.

박스플롯은 분포를 접어 보여준다

요소	뜻
박스 아래쪽	1사분위수
박스 안의 선	중앙값
박스 위쪽	3사분위수
박스 높이	가운데 50% 퍼짐
따로 찍힌 점	이상치 후보

수염은 일반적인 최솟값과 최댓값 범위를 나타낸다.

전체 주문금액은 평균이 높다



결과

평균이 중앙값보다 높아 큰 주문의 영향을 받는다.

평균 왜곡 후보는 치즈케이크다



결과

치즈케이크의 평균-중앙값 차이가 가장 크다.

수량 분포가 평균을 끌어올린다



결과

1개 주문이 가장 많지만 2·3개 주문 302건이 평균을 올린다.

오늘의 미션

미션 1. 부서별 연봉 요약

평균, 중앙값, 범위, 표준편차, 이상치 수를 구한다.

미션 2. 평균 왜곡 찾기

치즈케이크처럼 평균이 보통값을 과장하는 사례를 설명한다.

정리

- 평균은 전체 수준을 빠르게 보여 준다.
- 중앙값과 최빈값은 보통의 위치를 보완한다.
- 표준편차와 박스플롯은 퍼짐과 이상치를 보여 준다.

다음 차시 — 평균 해석을 다음 분석 실습에 연결한다.