

S06 · PART 02 · 통계 · 난이도 3


상관과 인과, 심슨의 역설

함께 움직이는 관계와 원인을 구분하고 평균의 함정을 살핀다.

오늘의 학습 목표

- 01 산점도와 r 로 두 변수의 관계를 읽는다
- 02 상관과 인과를 구분해 설명한다
- 03 전체 평균과 그룹 평균을 비교한다
- 04 그럴듯한 주장을 데이터로 반박한다

두 열을 함께 살핀다



두 변수 관계와 그룹 분해가 핵심이다.

오늘은 표에서 열 하나만 보는 것이 아니라, 두 열을 나란히 놓고 봅니다. 예를 들어 아파트 전용면적과 거래금액, 기온과 매출, 성별과 연봉처럼 두 값이 함께 움직이는지 살펴보는 방식입니다.

그림은 통계에서 자주 하는 두 가지 일을 떠올리게 합니다. 하나는 두 숫자 열의 관계를 보는 일이고, 다른 하나는 전체를 부서나 성별 같은 그룹으로 나누어 다시 보는 일입니다. 키와 몸무게를 같이 재듯이, 데이터도 한 가지 숫자만 보면 놓치는 관계가 생깁니다.

여기서 조심할 점이 있습니다. 두 값이 같이 움직인다고 해서 바로 한쪽이 다른 쪽의 원인이라고 말할 수는 없습니다. 같이 움직였는지 보는 것과, 왜 그렇게 되었는지 따지는 것은 서로 다른 질문입니다.

r은 함께 움직이는 정도를 요약한다

상관계수 r 은 -1부터 1 사이에서 두 숫자 열이 함께 움직이는 정도를 나타낸다.


- 1에 가까우면 함께 커진다
- 0에 가까우면 함께 움직임이 약하다
- -1에 가까우면 반대로 움직인다

상관계수 r 은 두 숫자 열이 얼마나 같이 움직이는지 한 숫자로 줄여서 보여주는 값입니다. 값은 -1부터 1 사이에 있습니다. 체온계가 온도를 숫자 하나로 보여주듯이, r 은 두 열의 관계를 숫자 하나로 요약해 줍니다.

r 이 1에 가까우면 한쪽이 커질 때 다른 쪽도 커지는 경향이 강합니다. 아파트 전용면적이 커질수록 거래 금액도 대체로 높아지는 경우가 여기에 가깝습니다. r 이 -1에 가까우면 한쪽이 커질 때 다른 쪽은 작아지는 경향입니다. r 이 0에 가까우면 두 값이 같이 움직인다고 보기 어렵습니다.

다만 r 은 관계의 방향과 강도를 알려 주는 숫자이지, 원인을 알려 주는 숫자는 아닙니다. 사전에서 단어 뜻을 찾듯이 r 을 읽되, 그 숫자 하나만 보고 결론을 끝내지는 않아야 합니다.

거래금액을 숫자로 바꾼다



결과


숫자형이어야 $r=0.806$ 을 계산할 수 있다.

이 표는 같은 아파트 거래 자료를 계산하기 전과 후로 비교한 그림입니다. 왼쪽은 거래금액이 십표가 들어간 문자처럼 읽힌 상태이고, 오른쪽은 거래금액을 계산 가능한 숫자로 바꾼 상태입니다. 행수는 3,754행으로 그대로이고, 바뀐 것은 금액 열의 성격입니다.

엑셀에서는 134,500처럼 십표가 들어간 값이 때로는 숫자가 아니라 글자로 취급될 수 있습니다. 글자로 읽힌 금액은 더하거나 평균을 내거나 상관계수를 계산할 때 문제가 됩니다. 계산하려면 금액을 저울에 올릴 수 있는 숫자처럼 만들어야 합니다.

그래서 수업 자료 페이지에서 내려받은 아파트 실거래 표에서 거래금액 열을 새 숫자 열로 바꿉니다. 이렇게 해야 전용면적과 거래금액의 상관계수 $r=0.806$ 을 계산할 수 있습니다. 모양은 금액처럼 보여도, 엑셀이 숫자로 이해하는지가 중요합니다.

면적과 금액은 함께 움직인다



결과

강남구 3,754건에서 **강한 양의 상관**이 확인된다.

이 막대는 전용면적과 거래금액의 상관계수를 보여줍니다. 상관계수 r 이 0.806으로 나왔습니다. r 은 -1부터 1 사이의 값이므로, 0.806은 1에 꽤 가까운 편입니다.

어디를 보면 될까요? 막대의 값과 표시된 $r = 0.806$ 을 보면 됩니다. 양수이기 때문에 전용면적이 커질수록 거래금액도 대체로 높아지는 방향입니다. 값이 0에 가까운 것이 아니라 0.806이므로, 관계가 약하다고 보기는 어렵습니다.

면적과 금액은 함께 움직인다 이어서

그래서 강남구 아파트 실거래 3,754건에서는 면적과 거래금액이 함께 움직인다고 말할 수 있습니다. 다만 이 말은 '면적이 가격의 전부를 결정한다'는 뜻이 아닙니다. 같은 면적 이어도 단지, 위치, 층, 연식, 거래 시점이 다르면 가격은 달라질 수 있습니다.

상관은 원인이 아니다

상관은 함께 움직였다는 뜻이고, 인과는 A가 B를 일으켰다는 뜻이다.


- 제3의 요인이 있을 수 있다
- 방향이 반대일 수 있다
- 우연히 함께 움직일 수 있다

상관은 두 값이 같이 움직였다는 뜻입니다. 인과는 A가 B를 일으켰다는 뜻입니다. 두 말은 비슷하게 들리지만 데이터 분석에서는 반드시 나누어 생각해야 합니다.

예를 들어 더운 날 아이스크림 판매도 늘고 물놀이 사고도 늘었다고 해 봅시다. 그렇다고 아이스크림이 사고를 일으켰다고 말할 수는 없습니다. 더운 날씨나 휴가철처럼 둘 모두에 영향을 주는 다른 요인이 있을 수 있습니다. 이런 것을 제3의 요인이라고 부릅니다.

또 방향을 잘못 볼 수도 있습니다. A가 B를 만든 것인지, B가 A를 만든 것인지 모를 때가 있습니다. 기간을 짧게 잘라 보면 우연히 같이 움직인 것처럼 보일 수도 있습니다. 그래서 상관을 발견하면 바로 결론을 내리지 말고, 다른 설명이 가능한지 한 번 더 물어봐야 합니다.

직관과 데이터가 어긋난다



결과

기온-통화건수는 **거의 0**으로, 주장을 지지하지 않는다.

이 막대는 기온과 배달 통화건수가 같이 움직이는지 본 참고 사례입니다. 겉으로는 기온이 배달과 관련 있을 것처럼 느껴질 수 있습니다. 그런데 상관계수는 $r = 0.015$ 입니다.


여기서는 0.015라는 숫자를 보면 됩니다. r 은 0에 가까울수록 두 값이 함께 움직이는 경향이 약하다는 뜻입니다. 0.015는 거의 0에 붙어 있으므로, 이 데이터에서는 기온과 통화건수가 뚜렷하게 같이 움직인다고 보기 어렵습니다.

직관과 데이터가 어긋난다

이어서

그래서 '기온이 오르면 배달 통화가 늘어난다'처럼 그럴듯하게 들리는 말도 바로 믿으면 안 됩니다. 먼저 같은 기준으로 데이터를 맞추고, 산점도와 상관계수로 확인해야 합니다. 직감은 출발점일 수 있지만 결론은 데이터로 확인해야 합니다.

전체 평균은 남성이 높다



결과

전체만 보면 남성이 **3,385,971원** 높다.

이 막대그래프는 직원 전체를 성별로만 나누어 평균 연봉을 비교한 그림입니다. 남성 평균은 67,296,571원이고 여성 평균은 63,910,600원입니다.


어디를 보면 될까요? 두 막대의 높이를 비교하면 됩니다. 남성 막대가 여성 막대보다 높고, 표시된 차이는 3,385,971원입니다. 전체 직원만 한꺼번에 보면 남성 평균 연봉이 더 높다는 결론이 나옵니다.

전체 평균은 남성이 높다

이어서

하지만 여기서 멈추면 위험합니다. 전체 평균은 여러 부서의 사람이 한 바구니에 섞인 값입니다. 사과와 배를 한 봉지에 넣고 무게를 잰 것처럼, 어떤 부서 사람이 더 많이 들어 있는지에 따라 평균이 달라질 수 있습니다.

부서별로 결론이 뒤집힌다



결과

부서로 나누면 5개 모두 **여성 평균이 높다**.

이 막대그래프는 전체 평균이 아니라 부서별로 나누어 여성 평균과 남성 평균의 차이를 본 그림입니다. 값은 여성 평균에서 남성 평균을 뺀 금액입니다. 그래서 값이 양수이면 그 부서에서는 여성 평균이 더 높다는 뜻입니다.

막대 5개를 하나씩 보면 개발본부 3,433,286원, 고객운영팀 2,597,500원, 데이터전략팀 5,229,365원, 영업본부 4,510,909원, 인사총무팀 1,570,769원입니다. 모두 0보다 큼니다. 특히 데이터전략팀은 5,229,365원으로 차이가 가장 큼니다.

부서별로 결론이 뒤집힌다

이어서

여기서 결론이 뒤집힙니다. 전체 평균만 보면 남성이 높았는데, 부서 안에서 비교하면 5개 부서 모두 여성 평균이 높습니다. 이런 현상을 심슨의 역설이라고 부릅니다. 전체로 볼 때와 중요한 그룹으로 나누어 볼 때 결론이 반대로 보이는 현상입니다.

왜 이런 일이 생길까요? 성별 자체보다 부서 구성이 전체 평균에 크게 영향을 주었기 때문입니다. 연봉 수준이 높은 부서에 남성이 더 많이 모여 있고, 낮은 부서에 여성이 더 많이 모여 있으면 전체 평균은 남성이 높아 보일 수 있습니다. 같은 부서 안에서 비교해야 더 공정한 비교에 가까워집니다.

부서별 평균을 함께 확인한다

부서	남성	여성
개발본부	73,541,000원	76,974,286원
고객운영팀	51,497,500원	54,095,000원
데이터전략팀	67,437,778원	72,667,143원

전체 평균과 부서별 평균의 결론이 반대다.

이 표는 막대그래프에서 본 내용을 숫자로 다시 확인하는 표입니다. 행은 부서이고, 열은 남성 평균 연봉과 여성 평균 연봉입니다. 그래프가 큰 흐름을 보여준다면, 표는 정확한 금액을 사전에서 찾듯 확인하게 해 줍니다.

각 행을 왼쪽부터 오른쪽으로 읽어 보세요. 개발본부는 남성 73,541,000원, 여성 76,974,286원입니다. 고객운영팀은 남성 51,497,500원, 여성 54,095,000원입니다. 데이터전략팀, 영업본부, 인사총무팀도 모두 여성 평균이 남성 평균보다 높습니다.

이 표에서 중요한 것은 전체 평균과 부서별 평균이 서로 다른 말을 한다는 점입니다. 전체 평균은 남성이 높다고 말했지만, 부서별 표는 모든 부서에서 여성이 높다고 말합니다. 그래서 평균을 볼 때는 '무엇끼리 섞어서 평균을 냈는지'를 꼭 확인해야 합니다.

부서별 평균을 함께 확인한다 (이어서)

부서	남성	여성
영업본부	61,020,000원	65,530,909원
인사총무팀	58,280,000원	59,850,769원

왜 뒤집히는가

성별 자체보다 부서 구성이 전체 평균에 큰 영향을 준다.

- 전체 평균만 보면 구조를 놓친다
- 비교 기준에 맞게 그룹을 나눈다
- 심슨의 역설은 분해로 확인한다

결론이 뒤집힌 이유는 전체 평균 안에 부서 구성이 숨어 있기 때문입니다. 평균은 한 줄로 보기에 편하지만, 그 안에 어떤 사람들이 얼마나 섞였는지는 가려 버립니다.

심슨의 역설은 전체로 보면 A가 높아 보이는데, 중요한 그룹으로 나누어 보면 모든 그룹에서 B가 높게 나오는 현상입니다. 방금 본 연봉 예시에서는 전체 평균만 보면 남성이 높지만, 부서별로 나누면 5개 부서 모두 여성 평균이 높았습니다.

그래서 분석할 때는 전체 평균을 버리라는 뜻이 아닙니다. 전체 평균을 본 뒤에, 비교에 영향을 줄 만한 기준으로 한 번 더 나누어 보라는 뜻입니다. 부서, 직급, 연차, 지역, 기간처럼 결과에 영향을 줄 수 있는 기준을 확인해 보세요.

오늘의 미션

미션 1. 주장 반박문 작성

기온과 매출을 날짜 기준으로 맞춘 뒤 상관과 다른 요인을 점검한다.

정리

- $r=0.806$ 은 강한 상관이지 인과를 단정할 근거는 아니다.
- 전체 평균은 남성이 높지만 부서별 평균은 모두 여성이 높다.
- 그럴듯한 주장은 산점도, r , 그룹 분해로 검토한다.

다음 차시: 엑셀을 AI에 업로드해 자연어로 분석