

S06 · PART 02 · 통계 · 난이도 3

상관 vs 인과, 심슨의 역설

숫자 두 개가 함께 움직인다는 사실과, 한쪽이 다른 한쪽의 원인이라는 주장을 구분한다.

오늘 끝나면 할 수 있는 것

- 01 산점도와 상관계수로 두 수치형 변수의 관계를 읽는다.
- 02 상관계수가 높아도 원인이라고 단정할 수 없음을 설명한다.
- 03 전체 평균만 보면 틀릴 수 있고, 필요한 기준으로 나누어 봐야 함을 이해한다.
- 04 기온이 오르면 매출이 늘어난다는 주장을 데이터 관점에서 검토하고 반박한다.

상관계수는 두 열이 같이 움직이는 정도 다

상관계수는 보통 r 로 표시하며, 값은 -1부터 1 사이에 있다. 엑셀에서는 CORREL 함수로 구하고, 파이썬 pandas에서는 .corr()로 구한다.

- **1에 가까움:** 한쪽이 커질수록 다른 쪽도 커지는 경향이 강하다.
- **0에 가까움:** 두 값이 함께 움직이는 경향이 거의 없다.
- **-1에 가까움:** 한쪽이 커질수록 다른 쪽은 작아지는 경향이 강하다.

산점도는 한 행을 한 점으로 보는 차트다

산점도는 원자료의 각 행을 하나의 점으로 찍어서 두 숫자 사이의 관계를 눈으로 본다.

- 강남구 아파트 실거래 데이터에서 한 행은 한 건의 거래다.
- x축은 전용면적(m^2), y축은 거래금액_만원, 점 하나는 아파트 거래 한 건이다.
- 강남구 아파트 실거래 3,754건에서 전용면적과 거래금액의 Pearson 상관계수는 $r = 0.806$ 이다.

상관은 인과가 아니다

상관은 같이 움직였다는 말이고, 인과는 A가 B를 일으켰다는 말이다. 상관계수가 높아도 원인은 아닐 수 있다.

- 전용면적과 거래금액은 강한 양의 상관을 보이지만, 면적이 가격의 유일한 원인이라는 뜻은 아니다.
- 같은 면적이라도 단지, 위치, 층, 연식, 거래 시점, 조망, 학군 같은 요소가 가격을 바꿀 수 있다.
- 배달 통화건수와 평균기온은 직관적으로 관련 있어 보일 수 있지만, 참고 데이터에서는 상관계수가 $r = 0.015$ 로 거의 0에 가깝다.

상관을 인과로 착각할 때 생기는 문제

문제	설명
제3의 요인	A와 B가 같이 움직이지만 실제로는 C가 둘 다에 영향을 줄 수 있다.
방향 혼동	A가 B를 만든 것인지, B가 A를 만든 것인지 알 수 없다.
우연한 동행	기간을 잘라 보면 우연히 같이 움직일 수 있다.

데이터 분석에서 그럴듯한 말은 결론이 아니라 가설이다.

심슨의 역설은 나누어 보면 결론이 뒤집히는 현상이다

심슨의 역설은 전체로 보면 A가 높아 보이지만, 중요한 그룹으로 나누어 보면 모든 그룹에서 B가 높게 나오는 현상이다.

- HR 직원 데이터는 1,200행이다.
- 전체 평균 연봉만 보면 남성 평균은 67,296,571원, 여성 평균은 63,910,600원이다.
- 전체만 보면 남성 평균이 3,385,971원 높지만, 부서별로 나누면 5개 부서 모두에서 여성 평균이 남성 평균보다 높다.

부서별 평균은 전체 평균과 다른 결론을 보인다

부서	남성 평균	여성 평균	여성 - 남성
개발본부	73,541,000원	76,974,286원	3,433,286원
고객운영팀	51,497,500원	54,095,000원	2,597,500원
데이터전략팀	67,437,778원	72,667,143원	5,229,365원
영업본부	61,020,000원	65,530,909원	4,510,909원
인사총무팀	58,280,000원	59,850,769원	1,570,769원

성별 자체보다 부서 구성이 전체 평균에 큰 영향을 준다.

“핵심은 반박의 태도다. 틀렸다고만 말하는 것이 아니라 이 주장에는 어떤 확인이 빠져 있다고 말해야 한다.”

오늘의 미션

미션 1. 아파트 상관 해석하기

강남구 아파트 실거래 3,754건에서 전용면적과 거래금액의 상관계수 $r = 0.806$ 을 한 문장으로 해석하고, 인과 단정이 아님을 함께 쓴다.

미션 2. HR 평균 뒤집힘 설명하기

전체 평균은 남성이 높지만, 부서별로 비교하면 5개 부서 모두에서 여성 평균 연봉이 더 높다는 결론을 설명한다.

미션 3. 기온과 매출 주장 반박하기

같은 날짜 기준의 기온과 매출 데이터가 필요하다는 점, 산점도와 상관계수 확인, 상관과 인과의 구분, 요일과 계절과 행사 같은 다른 요인을 포함해 반박문을 작성한다.

정리

- 상관계수는 두 숫자 열이 함께 움직이는 정도를 요약하지만, 원인을 증명하지는 않는다.
- 산점도는 원자료의 행을 점으로 보여 주므로 상관계수 하나보다 먼저 확인해야 한다.
- 전체 평균만 보면 남성이 높지만, 부서별로 나누면 모든 부서에서 여성 평균이 높으므로 그룹 기준을 함께 봐야 한다.

다음 차시 — 엑셀 파일을 AI에 올려 자연어로 분석하고, AI가 만든 표와 차트의 집계 기준과 제외 기준을 확인한다.