

S06 · PART 02 · 통계 · 난이도 3

상관과 인과, 심슨의 역설

함께 움직이는 관계와 원인을 구분하고 평균의 함정을 살핀다.

오늘의 학습 목표

- 01 산점도와 r 로 두 변수의 관계를 읽는다
- 02 상관과 인과를 구분해 설명한다
- 03 전체 평균과 그룹 평균을 비교한다
- 04 그럴듯한 주장을 데이터로 반박한다


두 열을 함께 살핀다

PART 02 · 통계

분포와 상관을 읽는다


분포 · 히스토그램

빈도 · 정규곡선




분포 · 박스플롯

사분위수 · 이상치



상관관계

molit 실거래가 · 전용면적 → 거래금액



상관은 인과가 아니다 — 심슨의 역설 주의

hr_employees 데이터에서 전체 경향과 그룹별 경향이 반대로 나타나는 사례가 확인됨

데이터셋 · molit 실거래가 ($r = 0.806$) · hr_employees (심슨의 역설)

STATISTICS

두 변수 관계와 그룹 분해가 핵심이다.

핵심 개념 1

r 은 함께 움직이는 정도를 요약한다

상관계수 r 은 -1부터 1 사이에서 두 숫자 열이 함께 움직이는 정도를 나타낸다.

- 1에 가까우면 함께 커진다
- 0에 가까우면 함께 움직임이 약하다
- -1에 가까우면 반대로 움직인다

거래금액을 숫자로 바꾼다

변환 전

거래금액(만원)

심표 포함 문자

행수

3,754행



변환 후

거래금액_만원

숫자


행수

3,754행

결과

숫자형이어야 $r=0.806$ 을 계산할 수 있다.

면적과 금액은 함께 움직인다



결과

강남구 3,754건에서 **강한 양의 상관**이 확인된다.

핵심 개념 2

상관은 원인이 아니다

상관은 함께 움직였다는 뜻이고, 인과는 A가 B를 일으켰다는 뜻이다.

- 제3의 요인이 있을 수 있다
- 방향이 반대일 수 있다
- 유연히 함께 움직일 수 있다


직관과 데이터가 어긋난다



결과

기온-통화건수는 **거의 0**으로, 주장을 지지하지 않는다.


전체 평균은 남성이 높다



결과

전체만 보면 남성이 3,385,971원 높다.

부서별로 결론이 뒤집힌다



결과

부서로 나누면 5개 모두 **여성 평균이 높다.**

부서별 평균을 함께 확인한다

부서	남성	여성
개발본부	73,541,000원	76,974,286원
고객운영팀	51,497,500원	54,095,000원
데이터전략팀	67,437,778원	72,667,143원
영업본부	61,020,000원	65,530,909원
인사총무팀	58,280,000원	59,850,769원

전체 평균과 부서별 평균의 결론이 반대다.

핵심 개념 3

왜 뒤집히는가

성별 자체보다 부서 구성이 전체 평균에 큰 영향을 준다.

- 전체 평균만 보면 구조를 놓친다
- 비교 기준에 맞게 그룹을 나눈다
- 심슨의 역설은 분해로 확인한다

오늘의 미션

미션 1. 주장 반박문 작성

기온과 매출을 날짜 기준으로 맞춘 뒤 상관과 다른 요인을 점검한다.

정리

- $r=0.806$ 은 강한 상관이지 인과를 단정할 근거는 아니다.
- 전체 평균은 남성이 높지만 부서별 평균은 모두 여성이 높다.
- 그럴듯한 주장은 산점도, r , 그룹 분해로 검토한다.

다음 차시: 엑셀을 AI에 업로드해 자연어로 분석