

S11 · PART 04 · 파이썬 · 난이도 3

Pandas 입문: CSV 필터

CSV를 읽고 표 구조를 확인한 뒤 조건 행을 남긴다.

이번 차시의 목표

- 01 DataFrame과 Series를 구분한다
- 02 CSV의 행 수와 열 구조를 확인한다
- 03 불리언 마스크로 행을 필터링한다
- 04 금액 기준으로 결과를 정렬한다

파이썬에서 표를 다룬다



오늘은 문법을 표 분석으로 연결한다.

파이썬을 표 분석에 쓰는 순간입니다. 지난 시간에는 변수나 조건문처럼 작은 부품을 배웠다면, 여기서는 그 부품으로 실제 카페 매출 표를 열어 봅니다.

CSV는 엑셀로도 열리는 표 파일입니다. pandas는 그 표를 파이썬 안으로 가져와서 행과 열을 확인하고, 원하는 조건의 주문만 남기게 해 주는 도구라고 보면 됩니다.

오늘 화면에서 봐야 할 흐름은 표를 읽고, 표 모양을 확인하고, 엑셀 필터처럼 조건에 맞는 행만 남기는 흐름입니다.

표 전체와 열 하나를 구분한다



결과

DataFrame에서 한 열을 꺼내면 **Series**가 된다.

왼쪽의 DataFrame은 표 전체입니다. 엑셀로 치면 시트 한 장 전체를 보는 느낌이고, 이 수업의 카페 매출 표는 10,424행 x 12열로 되어 있습니다.

오른쪽의 Series는 그 표에서 열 하나만 꺼낸 것입니다. 여기서는 amount, 즉 주문 금액 열 하나를 꺼냈기 때문에 길이가 10,424입니다. 행마다 주문 금액이 하나씩 들어 있으니 전체 행수와 길이가 같습니다.

표 전체와 열 하나를 구분하는 감각이 중요합니다. 냉장고 전체를 보는 것과 그 안의 음료 칸만 꺼내 보는 것이 다르듯이, DataFrame은 전체 표이고 Series는 그 안의 한 열입니다.

표 파일은 먼저 점검한다

도구	보는 것	의미
<code>shape</code>	행·열 개수	10,424 x 12
<code>columns</code>	열 이름	머리글 확인
<code>head</code>	앞쪽 행	파일 열림 확인

표 파일을 연 뒤 바로 분석하지 않는다.

표 파일을 열었다고 바로 분석을 시작하면 위험합니다. 엑셀 파일을 받았을 때도 먼저 시트가 제대로 열렸는지, 열 제목이 맞는지, 빈칸이 이상하게 섞였는지 훑어보죠. pandas에서도 같은 일을 먼저 합니다.

`shape`는 표의 크기를 봅니다. 여기서는 10,424 x 12니까 주문 기록이 10,424행 있고, 열이 12개 있다는 뜻입니다. `columns`는 머리글을 확인하는 도구라서 어떤 열 이름들이 있는지 봅니다.

`head`는 앞쪽 몇 행을 눈으로 보는 기능입니다. `info`는 열마다 숫자인지 글자인지, 빈칸이 있는지 보는 점검표이고, `describe`는 숫자 열의 평균, 최소, 최대 같은 범위를 빠르게 보는 도구입니다.

이 표는 분석 결과표라기보다 출발 전 안전 점검표입니다. 차를 몰기 전에 계기판을 보듯이, 표를 분석하기 전에 이 다섯 가지로 표 상태를 확인해 보세요.

표 파일은 먼저 점검한다 (이어서)

도구	보는 것	의미
info	타입·빈칸	구조 점검
describe	숫자 요약	범위 확인

주문 금액 범위를 먼저 확인한다



결과

주문 금액은 **3,000원~19,500원** 범위다.


이 막대그래프는 주문 한 건의 금액이 어느 정도 범위에 있는지 보여줍니다. 왼쪽은 가장 작은 주문 금액 3,000원, 가운데는 평균 주문 금액 8,681.17원, 오른쪽은 가장 큰 주문 금액 19,500원입니다.

볼 때는 오른쪽 끝의 최대값과 왼쪽 끝의 최소값을 먼저 보세요. 저울에 올려서 가장 가벼운 값과 가장 무거운 값을 재는 것처럼, 데이터의 양끝을 확인하는 일입니다.

주문 금액 범위를 먼저 확인한다 이어서

그래서 이 표의 주문 금액은 3,000원보다 작거나 19,500원보다 큰 값이 없다고 이해하면 됩니다. 만약 1,000,000원 같은 값이 끼어 있었다면 입력 오류인지 확인해야겠지만, 여기서는 카페 주문 금액으로 자연스러운 범위입니다.

강남점 행 수가 더 많다



결과

강남점이 **6,196행**으로 가장 많다.

이 막대그래프는 지점별로 주문 기록이 몇 행 있는지 세어 본 그림입니다. 강남점은 6,196행, 홍대점은 4,228행입니다.

막대의 높이는 매출액이 아니라 행 수입니다. 행 수는 주문 기록의 개수라고 보면 됩니다. 강남점 막대가 더 높다는 말은 강남점 주문 기록이 홍대점보다 더 많이 들어 있다는 뜻입니다.

여기서 바로 강남점 매출이 더 크다고 단정하지는 않습니다. 지금 확인한 것은 금액 합계가 아니라 주문 기록 개수입니다. 금액을 보려면 amount를 더해서 따로 계산해야 합니다.

필터는 먼저 조건을 만든다

지점 열이 강남점인지 행마다 판단해 결과를 True와 False로 만든다.

- True인 행만 loc로 남긴다
- 여러 조건은 괄호와 &로 연결한다

pandas에서 필터는 바로 행을 지우는 일이 아닙니다. 먼저 각 행에게 질문을 던집니다. 이 주문은 강남점 주문인가요? 맞으면 True, 아니면 False가 됩니다.

이렇게 True와 False로 길게 만들어진 열을 불리언 마스크라고 부릅니다. 불리언은 참과 거짓이라는 뜻이고, 마스크는 조건에 맞는 행만 통과시키는 체라고 생각하면 됩니다.

loc는 그 마스크를 보고 True인 행만 남깁니다. 엑셀 필터에서 강남점만 체크하면 강남점 행만 보이는 것과 같은 원리입니다.

조건이 여러 개일 때는 각 조건을 괄호로 감싸고 &로 이어 주세요. 강남점이면서 커피이고 금액이 10,000원 이상인 주문처럼, 여러 체를 차례로 통과시키는 느낌입니다.

조건에 맞는 행만 남긴다



결과

불리언 마스크를 적용하면 **강남점 6,196행**만 남는다.


왼쪽은 필터를 걸기 전 전체 표입니다. 행이 10,424개 있고, 지점에는 강남점과 홍대점이 함께 들어 있습니다.

오른쪽은 강남점인지 묻는 조건을 적용한 뒤입니다. True로 표시된 강남점 행만 남아서 6,196행이 되었습니다.

홍대점 데이터가 원본에서 사라진 것은 아닙니다. 원본 표는 그대로 두고, 강남점 조건에 맞는 행만 따로 꺼내 본 결과라고 이해하면 됩니다.

엑셀에서 필터를 걸면 화면에 보이는 행이 줄어드는 것과 같습니다. pandas에서는 그 일을 불리언 마스크와 loc가 나누어 맡습니다.

조건이 늘면 행이 줄어든다



결과

세 조건을 모두 적용하면 **1,362행**만 남는다.

이 그래프는 조건을 하나씩 더 붙일수록 남는 행이 어떻게 줄어드는지 보여줍니다. 전체 표는 10,424행이고, 강남점만 남기면 6,196행이 됩니다.

미션 조건은 여기서 한 번 더 좁힌 결과입니다. 강남점이면서, 카테고리가 커피이고, 주문 금액이 10,000원 이상인 행만 남기면 1,362행이 됩니다.

조건이 늘면 행이 줄어든다

이어서

막대가 줄어드는 것은 데이터가 잘못된 것이 아니라 조건이 더 까다로워졌다는 뜻입니다. 체에 구멍을 더 촘촘하게 만든다고 생각해 보세요. 통과하는 주문만 남기 때문에 행 수가 줄어드는 것이 자연스럽습니다.

미션 결과가 숫자로 요약된다

필터 전			
행수	10,424		
총금액	전체		
평균금액	전체		

→

미션 후			
행수	1,362		
총금액	16,664,500원		
평균금액	12,235.32원		

결과

미션은 **1,362행**, 총금액 **16,664,500원**이다.

왼쪽은 아직 조건을 적용하기 전이라 전체 10,424행을 보고 있는 상태입니다. 이때의 총금액과 평균금액은 전체 표를 대상으로 한 값입니다.

오른쪽은 미션 조건을 적용한 뒤입니다. 강남점, 커피, 10,000원 이상이라는 조건을 모두 통과한 주문이 1,362행 남았습니다.

총금액 16,664,500원은 그 1,362행의 주문 금액을 모두 더한 값입니다. 평균금액 12,235.32원은 그 주문들을 한 건씩 저울에 올려 평균을 낸 값이라고 보면 됩니다.

필터를 한 뒤에는 행수만 보지 말고 총금액과 평균금액도 같이 확인해 보세요. 조건이 제대로 걸렸는지 숫자로 다시 확인하는 습관이 생깁니다.

정렬하면 큰 금액이 위로 온다

순서	ORDER_ID	AMOUNT
1	10029	16,500
2	10064	16,500
3	10085	16,500

같은 금액은 날짜와 주문번호로 정렬한다.

이 표는 미션 결과를 주문 금액이 큰 순서로 정렬한 뒤 위쪽 5개를 보여줍니다. amount는 주문 금액이고, order_id는 주문을 구분하는 번호입니다.

위에 있는 5개 행의 금액이 모두 16,500입니다. 지금 보이는 결과에서는 16,500원이 가장 큰 주문 금액이라서 맨 위에 모여 있습니다.

같은 금액이 여러 개 있으면 순서가 흔들릴 수 있습니다. 그래서 날짜와 주문번호를 보조 기준으로 함께 써서, 같은 16,500원 안에서도 일정한 순서로 보이게 합니다.

정렬은 원본 표를 망가뜨리는 작업이 아닙니다. 엑셀에서 금액 열을 큰 값부터 보기 좋게 정렬하듯이, 분석 결과를 읽기 쉬운 순서로 바꿔 보는 과정입니다.

정렬하면 큰 금액이 위로 온다 (이어서)

순서	ORDER_ID	AMOUNT
4	10108	16,500
5	10114	16,500

오늘의 미션

미션 1. 조건 행 추출

강남점·커피·10,000원 이상 주문만 남긴다.

미션 2. 금액순 정렬

amount가 큰 순서로 결과를 정렬한다.

미션 3. 결과 요약

행수, 총금액, 평균금액을 출력한다.

정리

- DataFrame은 표 전체, Series는 열 하나다.
- CSV는 shape, info, describe로 먼저 점검한다.
- pandas에서는 엑셀 필터를 **불리언 마스크**로 다룬다.
- loc로 조건 행을 남기고 sort_values로 정렬한다.

다음 차시 — dirty 데이터를 열고 결측, 중복, 타입, 인코딩을 정리한다.