

S12 · PART 04 · 파이썬 · 난이도 4

데이터 정제: 7가지 기준

결측과 이상치를 처리해 계산 가능한 표로 만든다.

학습 후 할 수 있는 것

- 01 결측·중복·타입 문제를 수치로 진단한다
- 02 문자열 표기와 날짜를 계산 가능하게 바꾼다
- 03 정제 전후 행수와 통계 변화를 설명한다

파이썬으로 기준을 남긴다

PART 04 · 파이썬

코드로 남기는 분석


analysis.py

```
1 import pandas as pd
2
3 df = pd.read_csv("cafe_sales.csv")
4
5 # 지점별 매출 합계
6 df.groupby("store")["amount"].sum()
```



지점별 매출

cafe_sales · store 기준 groupby().sum()




결과 · 강남점 매출 > 홍대점 매출 · 코드 6줄로 재현 가능

REPRODUCIBLE ANALYSIS

정제 기준을 코드로 남겨 같은 파일에 반복 적용한다.

문제는 먼저 수치로 본다



결과

결측과 공백 표기가 먼저 크게 드러난다.

결측은 기준으로 채운다

정제 전

payment	313건
member	209건



정제 후

payment	미확인
member	False
전체 결측	0건

결과

주문은 유지하고 결측 처리 기준만 명시한다.

표기 차이를 통일한다

정제 전

강남 점	310건
category 공백	313건
아메리카노 변형	106건



정제 후

store	공백 제거
category	strip 적용
item	아메리카노 통일

결과

같은 지점과 메뉴가 한 그룹으로 집계된다.

문자와 날짜를 타입화한다

정제 전

unit_price 문자 포함 157건

YYYY/MM/DD 206건

MM-DD-YYYY 104건

날짜 실패 0건



정제 후

unit_price 변환 실패 0건

date datetime

날짜 실패 0건

결과

문자 단가와 섞인 날짜를 계산 가능한 타입으로 바꾼다.

IQR로 수량 999를 탐지한다

IQR 기준

Q1 1.0

Q3 2.0

정상범위 -0.5~3.5

qty=999 2행



제거 후

이상치 2행 제거

최대 수량 3

검산 불일치 0건

결과

정상 범위 밖 2행을 제거해 최대 수량은 3이 된다.

행수는 18행 줄어든다

정제 전

행수 10,439

고유 order_id 10,424

중복 order_id 15행

최소 금액 -5,500원



정제 후

행수 10,421

고유 order_id 10,421


중복 order_id 0행

최소 금액 3,000원

결과

중복 15행, 이상치 2행, 음수 1행을 제외한다.


판매수량 합계가 바뀐다



결과

qty=999 두 행이 원본 수량 합계를 크게 높였다.

총매출은 거의 유지된다



결과

총매출은 90,476,000원으로 소폭 낮아진다.

cp949는 옵션을 지정해 읽는다

기본 읽기

읽기 결과

UnicodeDecodeError



ENCODING 지정

encoding

cp949

정상 로드

1,947행 x 15열

날짜 실패

0건

날짜 범위

2013-12-01~2019-03-31

결과

인코딩을 지정하면 한글 CSV와 날짜가 정상 처리된다.

오늘의 미션

미션 1. 문제 요약표

결측, 중복, 타입, 표기 문제를 수치로 정리한다.

미션 2. 정제 전후 비교표

행수, 매출, 수량, 최댓값·최솟값을 비교한다.

미션 3. 해석 문장

판매수량 변화가 qty=999 두 행 때문임을 설명한다.

정리

- 결측값은 의미에 따라 채우거나 제외한다.
- 문자 숫자와 날짜는 계산 가능한 타입으로 바꾼다.
- 정제 후 10,421행으로 분석 기준이 명확해진다.

다음 차시: 정제한 표로 집계와 시각화를 이어간다.