

데이터 정제: 결측, 이상치, 타입, 중복, 문자열, 인코딩, 날짜

pandas로 데이터를 읽은 뒤 결측, 중복, 타입, 문자열, 이상치, 인코딩, 날짜 문제를 점검하고 계산 가능한 표로 만드는 과정을 익힌다.

오늘 끝나면 할 수 있는 것

- 01 isna, fillna, dropna로 결측값을 찾고 처리한다.
- 02 to_numeric, astype, to_datetime으로 계산 가능한 타입을 만든다.
- 03 drop_duplicates로 중복 행과 중복 키를 구분한다.
- 04 .str.strip, .str.replace, replace로 문자열 표기 흔들림을 정리한다.
- 05 IQR 기준으로 수량 이상치를 찾아 제거하고 정제 전후 통계를 설명한다.
- 06 cp949 한글 CSV를 encoding 옵션으로 읽고 날짜 문자열을 datetime으로 바꾼다.

핵심 개념 1

정제는 계산 가능한 표를 만드는 일이다

데이터 정제는 표를 예쁘게 꾸미는 일이 아니라 평균, 합계, 피벗테이블, 그래프가 흔들리지 않도록 계산 가능한 상태로 만드는 일이다.

- 잘못된 수량 999, 음수 금액, 같은 order_id 중복, 문자로 섞인 단가는 분석 결과를 혼돈다.
- 정제의 첫 단계는 고치는 것이 아니라 행수, 열, 결측, 중복을 숫자로 남기는 일이다.
- 원본 df는 그대로 두고 cleaned 복사본으로 정제 전후를 비교한다.

dirty 데이터에서 먼저 확인한 문제

점검 항목	확인값
전체 크기	10,439행 x 12열
고유 order_id	10,424개
중복 order_id 행	15
완전 동일 중복 행	13
payment 결측	313
member 결측	209
날짜 형식 혼합	YYYY/MM/DD 206건, MM-DD-YYYY 104건
unit_price 문자 포함	157
store= '강남 점'	310
category 앞뒤 공백	313
아메리카노 표기 변형	106
qty= 999	2

결측값은 무조건 삭제하지 않는다

결측값은 빈칸이 아니라 처리 기준을 정해야 하는 값이다. 어떤 빈칸은 모름으로 채우고, 어떤 빈칸은 분석에서 제외한다.

- payment 결측 313건은 주문 자체를 버릴 필요가 없으므로 미확인으로 채운다.
- member 결측 209건은 이번 실습 기준으로 False로 채운다.
- 필수 열 결측은 `dropna(subset=...)`로 제외하지만, 이번 데이터에서는 제거 행수가 0행이다.

눈에 보이는 값과 실제 타입은 다를 수 있다

4,500원은 사람에게 단가처럼 보이지만 컴퓨터에는 문자다. 쉼표와 원 표시를 지운 뒤 숫자로 변환해야 합계와 평균을 계산한다.

- unit_price 문자 포함 157건은 쉼표와 원 표시를 제거한 뒤 to_numeric으로 바꾼다.
- 날짜는 pd.to_datetime(..., format='mixed')로 datetime 타입으로 바꾸며, 날짜 변환 실패는 0건이다.
- cp949 원본 파일은 기본 읽기에서 UnicodeDecodeError가 나고, encoding='cp949'로 읽으면 1,947행 x 15열로 정상 로드된다.
- cp949 원본 파일의 날짜 범위는 2013-12-01부터 2019-03-31까지다.

중복과 문자열은 집계 그룹을 바꾼다

같은 주문이나 같은 지점도 표기가 다르면 별도 값으로 집계된다. 분석 기준이 되는 키와 그룹명부터 통일해야 한다.

- 거래 1건을 식별하는 키는 order_id이므로 order_id 기준으로 중복 15행을 제거한다.
- 강남점과 강남 점은 다른 값이므로 store의 앞뒤 공백과 내부 공백을 정리한다.
- 아메리카, Americano, 아메 리카노는 아메리카노로 통일한다.

이상치는 삭제하기 전에 확인한다

이상치는 나쁜 값이 아니라 확인해야 할 값이다. 이번 데이터의 qty=999는 카페 주문 수량으로 보기 어렵고 IQR 기준에서도 정상범위를 벗어난다.

- 수량의 Q1은 1.0, Q3는 2.0, IQR은 1.0이다.
- IQR 기준 정상범위는 -0.5부터 3.5까지이며, qty=999인 2행이 이상치로 잡힌다.
- amount 음수 1행은 주문 금액 오류로 보고 제거한다.

청소 전후 비교

비교 항목	청소 전	청소 후
행수	10,439	10,421
고유 order_id	10,424	10,421
총매출	90,600,500원	90,476,000원
판매수량 합계	19,259	17,238
건당 평균금액	8,679원	8,682원
건당 중앙값	6,500원	6,500원
최대 수량	999	3
최소 금액	-5,500원	3,000원

정제 후에는 중복 order_id, 전체 결측값, 단가 x 수량과 금액 불일치가 모두 0이다.

오늘의 미션

미션 1. 문제 요약표 만들기

cafe_sales_dirty.csv에서 결측, 중복, 날짜 형식, 문자 숫자, 문자열 표기, 이상치를 확인하는 요약표를 만든다.

미션 2. 정제 전후 비교표 만들기

정제 전후 행수, 고유 order_id, 총매출, 판매수량 합계, 최대 수량, 최소 금액을 비교한다.

미션 3. 해석 문장 작성하기

정제 전 10,439행에서 중복 15행, qty=999 이상치 2행, amount 음수 1행을 제외해 10,421행이 되었다고 설명한다.

정리

- 정제는 계산 가능한 표를 만들고 처리 기준을 코드로 남기는 일이다.
- 결측은 의미에 따라 채우거나 제외하고, 문자 숫자와 날짜는 계산 가능한 타입으로 바꾼다.
- 중복 order_id 15행, qty=999 이상치 2행, amount 음수 1행을 제외해 정제 후 10,421행으로 분석한다.
- cp949 파일은 encoding 옵션으로 다시 읽고, 날짜 문자열은 datetime으로 변환한다.

다음 차시 — S13에서는 여러 행을 요약표로 바꾸는 그룹화·집계·재구조화를 다룬다.