

S12 · PART 04 · 파이썬 · 난이도 4


데이터 정제: 7가지 기준

결측과 이상치를 처리해 계산 가능한 표로 만든다.

학습 후 할 수 있는 것

- 01 결측·중복·타입 문제를 수치로 진단한다
- 02 문자열 표기와 날짜를 계산 가능하게 바꾼다
- 03 정제 전후 행수와 통계 변화를 설명한다

파이썬으로 기준을 남긴다



정제 기준을 코드로 남겨 같은 파일에 반복 적용한다.

데이터 정제는 표를 예쁘게 꾸미는 일이 아니라, 계산해도 되는 상태로 만드는 일입니다. 엑셀에서 빈칸을 찾고, 중복 제거 버튼을 누르고, 숫자처럼 보이는 문자를 숫자로 바꾸는 작업을 파이썬으로 해 보는 것이죠.


그림에서 파이썬을 기준으로 정제 흐름이 이어지는 점을 보시면 됩니다. 한 번 기준을 코드로 남기면, 같은 종류의 매출 파일이 다시 와도 손으로 기억해서 반복하지 않아도 됩니다. 레시피를 적어 두면 같은 요리를 다시 만들 수 있는 것처럼, 정제 기준도 코드로 남기면 같은 처리를 다시 적용할 수 있습니다.

파이썬으로 기준을 남긴다

이어서

오늘은 결측, 중복, 문자열 표기, 숫자 타입, 날짜 타입, 이상치처럼 초보자가 자주 만나는 문제를 하나씩 확인합니다. 중요한 것은 바로 고치는 것이 아니라, 먼저 어디에 문제가 몇 건 있는지 숫자로 보고 나서 고치는 것입니다.

문제는 먼저 수치로 본다



결과

결측과 공백 표기가 먼저 크게 드러난다.

이 막대그래프는 카페 매출 표를 고치기 전에 어떤 문제가 몇 건 있는지 세어 본 그림입니다. 결측은 값이 비어 있거나 빠진 상태를 말합니다. 막대가 길수록 먼저 확인해야 할 문제가 많다는 뜻입니다.

왼쪽부터 보면 payment 결측이 313건, member 결측이 209건, 단가 문자가 157건입니다. 또 강남 점처럼 띄어쓰기가 섞인 지점명이 310건, category 공백도 313건입니다. 가장 큰 값이 313건이라서 payment 결측과 category 공백이 눈에 먼저 들어와야 합니다.

문제는 먼저 수치로 본다 이어서

그래프가 말하는 내용은 단순합니다. 바로 평균이나 매출 합계를 내기 전에, 빈칸과 표기 흔들림을 먼저 잡아야 한다는 뜻입니다. 키를 재기 전에 줄자가 제대로 놓였는지 확인하듯이, 분석 전에는 표가 계산 가능한 상태인지 먼저 재 봅니다.

결측은 기준으로 채운다

정제 전

payment313건

member209건

→

정제 후

payment미확인

memberFalse

전체 결측0건

결과

주문은 유지하고 결측 처리 기준만 **명시**한다.

이 표는 빈칸이 있는 주문을 무조건 버리지 않고, 기준을 정해서 채운 전후 비교입니다. 왼쪽은 정제 전 상태입니다. payment는 313건이 비어 있고, member는 209건이 비어 있습니다.

오른쪽은 처리 후 상태입니다. 결제수단을 모르는 주문은 주문 자체를 버리지 않고 미확인으로 채웁니다. 회원 여부가 비어 있는 값은 이번 실습 기준으로 False, 즉 비회원으로 처리합니다. 그래서 전체 결측이 0건이 됩니다.

여기서 중요한 판단은 삭제가 아니라 기준입니다. 결제수단이 비어 있어도 매출과 수량 분석에는 쓸 수 있으니 남겨 둡니다. 대신 나중에 누가 봐도 알 수 있게 미확인이라는 이름표를 붙여 두는 것입니다.

표기 차이를 통일한다



결과

같은 지점과 메뉴가 한 그룹으로 집계된다.

이 표는 사람 눈에는 같은 값처럼 보여도 컴퓨터에는 다르게 보이는 표기 차이를 고치는 장면입니다. 왼쪽을 보면 강남 점이 310건, category 공백이 313건, 아메리카노 변형이 106건 있습니다.

컴퓨터는 강남점과 강남 점을 다른 글자로 봅니다. 커피와 앞뒤에 빈칸이 붙은 커피도 다르게 봅니다. 사전에서 단어를 찾을 때 띄어쓰기 하나가 다르면 다른 위치로 가는 것과 비슷합니다.

오른쪽에서는 store의 공백을 제거하고, category에는 strip을 적용합니다. strip은 글자 앞뒤의 빈칸을 잘라 내는 기능입니다. item은 아메리카, Americano, 아메리카노처럼 흩어진 표기를 아메리카노로 맞춥니다. 이렇게 해야 피벗테이블이나 그룹별 집계에서 같은 지점과 같은 메뉴가 한 줄로 모입니다.

문자와 날짜를 타입화한다

정제 전

unit_price	문자 포함 157건
YYYY/MM/DD	206건
MM-DD-YYYY	104건
날짜 실패	0건



정제 후

unit_price	변환 실패 0건
date	datetime
날짜 실패	0건

결과

문자 단가와 석인 날짜를 계산 가능한 타입으로 바꾼다.

타입화는 겉으로만 숫자나 날짜처럼 보이는 값을, 컴퓨터가 실제로 계산할 수 있는 종류로 바꾸는 일입니다. 예를 들어 4,500원처럼 보이는 단가는 사람에게는 숫자지만, 쉼표와 원 표시가 붙어 있으면 컴퓨터에는 문자로 보일 수 있습니다.

왼쪽을 보면 unit_price에 문자가 포함된 값이 157건 있습니다. 날짜도 한 가지 모양이 아닙니다. YYYY/MM/DD 형식이 206건, MM-DD-YYYY 형식이 104건입니다. YYYY/MM/DD는 연/월/일 모양이고, MM-DD-YYYY는 월-일-연 모양입니다.

문자와 날짜를 타입화한다 이어서

오른쪽에서는 unit_price를 숫자로 바꾸었고 변환 실패가 0건입니다. date는 datetime으로 바뀌었습니다. datetime은 날짜 계산을 위한 전용 타입입니다. 날짜 실패도 0건이므로, 이제 월별 집계나 기간 필터를 해도 표가 제대로 따라옵니다.

IQR로 수량 999를 탐지한다

IQR 기준	
Q1	1.0
Q3	2.0
정상범위	-0.5~3.5
qty=999	2행



제거 후	
이상치	2행 제거
최대 수량	3
검산 불일치	0건

결과

정상 범위 밖 2행을 제거해 최대 수량은 3이 된다.

IQR은 데이터의 가운데 50퍼센트가 얼마나 퍼져 있는지 보는 기준입니다. 여기서는 수량을 저울에 올려서 평소 주문 범위 안에 있는지 확인한다고 생각하시면 됩니다.

왼쪽 기준을 보면 Q1이 1.0, Q3가 2.0입니다. 그래서 정상범위가 -0.5~3.5로 잡힙니다. 카페 주문 수량이 이 범위 안에 있으면 보통의 주문으로 보고, 훨씬 벗어나면 확인 대상으로 봅니다. qty=999는 이 범위를 한참 벗어난 값이고 2행이 잡혔습니다.

오른쪽은 그 2행을 제거한 뒤입니다. 최대 수량이 3으로 내려왔고, 검산 불일치가 0건입니다. 검산은 단가에 수량을 곱한 값이 금액과 맞는지 확인하는 작업입니다. 계산표에서 마지막으로 합이 맞는지 다시 눌러 보는 과정이라고 보시면 됩니다.

행수는 18행 줄어든다

정제 전			정제 후	
행수	10,439	→	행수	10,421
고유 order_id	10,424		고유 order_id	10,421
중복 order_id	15행		중복 order_id	0행
최소 금액	-5,500원		최소 금액	3,000원

결과


중복 15행, 이상치 2행, 음수 1행을 제외한다.

이 표는 정제 전과 정제 후에 표의 크기와 기본 상태가 어떻게 바뀌었는지 보여줍니다. 왼쪽은 정제 전입니다. 행수는 10,439이고, 고유 order_id는 10,424입니다. 행수보다 고유 주문번호가 적다는 것은 같은 주문번호가 반복된 줄이 있다는 뜻입니다.

정제 후를 보면 행수는 10,421로 줄고, 고유 order_id도 10,421입니다. 이제 한 주문번호가 한 행으로 정리된 상태입니다. 중복 order_id도 15행에서 0행이 되었습니다.

최소 금액도 -5,500원에서 3,000원으로 바뀝니다. 이번 카페 주문 데이터에서 음수 금액은 정상 주문 금액으로 보기 어렵기 때문에 제외합니다. 그래서 중복 15행, 수량 이상치 2행, 음수 금액 1행을 빼면 전체가 18행 줄어듭니다.

판매수량 합계가 바뀐다



결과

qty=999 두 행이 원본 수량 합계를 크게 높였다.


이 막대그래프는 정제 전후의 판매수량 합계를 비교한 그림입니다. 왼쪽 막대가 청소 전 19,259개이고, 오른쪽 막대가 청소 후 17,238개입니다. 두 막대 사이에는 2,021개 차이가 납니다.

여기서는 오른쪽으로 갈수록 표가 더 믿을 만해졌다고 보시면 됩니다. 청소 전에는 qty=999인 두 행이 들어 있어서 판매수량 합계가 크게 부풀어 있었습니다. 주문 두 줄이 전체 수량을 흔든 셈입니다.

판매수량 합계가 바뀐다 이어서

그래프를 볼 때는 막대의 높이 차이를 먼저 보고, 그다음 왜 차이가 났는지 원인을 붙여 말해 보세요. 이 경우에는 판매가 갑자기 줄었다고 해석하는 것이 아니라, 잘못 들어간 큰 수량을 제거해서 실제에 가까운 합계가 된 것으로 봅니다.

총매출은 거의 유지된다



결과

총매출은 **90,476,000원**으로 소폭 낮아진다.


이 막대그래프는 정제 전후의 총매출을 비교합니다. 청소 전은 90,600,500원이고, 청소 후는 90,476,000원입니다. 판매수량 그래프와 달리 두 막대의 차이가 아주 크지는 않습니다.

여기서 봐야 할 점은 수량 합계는 크게 바뀌었지만 총매출은 소폭만 낮아졌다는 점입니다. 수량 999 같은 값은 수량 통계를 크게 흔들지만, 이번 데이터의 총매출 변화는 상대적으로 작게 나타납니다.

총매출은 거의 유지된다 이어서

그래프를 해석할 때는 값 하나만 보지 말고 같이 비교해야 합니다. 판매수량은 19,259개에서 17,238개로 줄었고, 총매출은 90,600,500원에서 90,476,000원으로 낮아졌습니다. 그래서 이번 정제의 가장 큰 영향은 매출보다 수량 합계에서 더 잘 보입니다.

cp949는 옵션을 지정해 읽는다



결과

인코딩을 지정하면 한글 CSV와 날짜가 정상 처리된다.

CSV는 엑셀처럼 보이지만 실제로는 글자가 줄줄이 저장된 텍스트 파일입니다. 인코딩은 그 글자를 어떤 약속으로 저장했는지를 뜻합니다. 같은 한글이라도 저장 약속이 다르면 파이썬이 글자를 제대로 읽지 못할 수 있습니다.

왼쪽을 보면 기본 읽기에서는 `UnicodeDecodeError`가 납니다. 이 오류는 파일을 읽는 글자 약속이 맞지 않았다는 뜻입니다. 오른쪽처럼 encoding을 `cp949`로 지정하면 배달 음식 예제 파일이 1,947행 x 15열로 정상 로드됩니다.

cp949는 옵션을 지정해 읽는다

이어서

날짜도 같이 확인합니다. 날짜 실패가 0건이고, 날짜 범위가 2013-12-01~2019-03-31로 잡힙니다. 한글이 깨지지 않고 날짜도 계산 가능한 값으로 바뀌었으니, 이제 이 표도 분석에 사용할 준비가 된 것입니다.

오늘의 미션

미션 1. 문제 요약표

결측, 중복, 타입, 표기 문제를 수치로 정리한다.

미션 2. 정제 전후 비교표

행수, 매출, 수량, 최댓값·최솟값을 비교한다.

미션 3. 해석 문장

판매수량 변화가 qty=999 두 행 때문임을 설명한다.

정리

- 결측값은 의미에 따라 채우거나 제외한다.
- 문자 숫자와 날짜는 계산 가능한 타입으로 바꾼다.
- 정제 후 10,421행으로 분석 기준이 명확해진다.

다음 차시: 정제한 표로 집계와 시각화를 이어간다.