

S13 · PART 04 · 파이썬 · 난이도 4

그룹화·집계·재구조화

여러 표를 붙이고 집계표와 긴 표로 바꾸는 법을 익힌다.

수업 후 할 수 있는 일

- 01 여러 표를 키로 붙이고 누락을 확인한다
- 02 groupby와 agg로 요약표를 만든다
- 03 pivot_table과 melt로 구조를 바꾼다
- 04 큰 파일을 먼저 줄여 해석한다

오늘 사용할 도구는 pandas다



pandas로 붙이고, 묶고, 펼치고, 내린다.

pandas는 표 데이터를 다루는 파이썬 도구입니다. 엑셀에서 행과 열로 된 표를 열어 보고, 필요한 열을 붙이고, 합계를 내고, 피벗 테이블을 만드는 일을 파이썬 코드로 한다고 생각하시면 됩니다.

그림의 문장은 오늘 할 일을 네 가지 동작으로 줄여 말합니다. 붙인다는 것은 여러 표를 같은 열쇠로 이어 붙이는 일이고, 묶는다는 것은 지역별·카테고리별처럼 같은 기준끼리 모으는 일입니다. 펼친다는 것은 피벗 테이블처럼 행과 열로 비교표를 만드는 일이고, 내린다는 것은 열 이름에 숨어 있던 값을 세로로 내려 분석하기 쉬운 표로 바꾸는 일입니다.

오늘 사용할 도구는 pandas다 이어서

엑셀을 써 보셨다면 완전히 낯선 내용은 아닙니다. VLOOKUP, 부분합, 피벗 테이블, 파워쿼리의 열 피벗 해제를 pandas 이름으로 다시 배우는 수업이라고 보시면 됩니다.

주문 표 3개를 하나로 붙인다



결과


주문 행은 유지되고 고객·상품 열이 붙는다.

왼쪽은 표를 붙이기 전 모습입니다. 주문 표는 20,000행, 6열이고, 고객 표는 3,000행, 7열, 상품 표는 200행, 5열입니다. 주문 표에는 주문이 한 줄씩 들어 있지만, 고객 지역이나 상품 단가 같은 설명 정보는 따로 떨어져 있습니다.

오른쪽은 세 표를 붙인 뒤입니다. 행은 20,000행으로 그대로인데 열은 17열로 늘었습니다. 이 말은 주문 한 건 한 건은 잃어버리지 않고, 옆으로 고객 정보와 상품 정보만 붙었다는 뜻입니다. 엑셀에서 VLOOKUP으로 고객명이나 단가를 옆 열에 가져오는 장면을 떠올리면 됩니다.

여기서 꼭 봐야 할 숫자는 누락값 0입니다. 표를 붙였는데 지역이나 카테고리, 단가가 비어 있으면 열쇠가 맞지 않았다는 신호일 수 있습니다. 이번에는 주문 20,000행이 유지되고 누락값도 0이라서, 다음 계산으로 넘어갈 준비가 된 상태입니다.

매출은 병합한 뒤 계산한다



결과

병합한 뒤에야 전체 매출 **1,938,489,803원**을 계산한다.

왼쪽을 보면 매출을 바로 계산할 수 없는 이유가 보입니다. 단가는 상품 표에 있고, 수량은 주문 표에 있습니다. 매출이라는 열은 아직 없습니다. 재료가 서로 다른 서랍에 들어 있는 상태라고 보시면 됩니다.

표를 붙인 뒤에는 한 주문 행 안에 단가와 수량, 할인율이 함께 놓입니다. 그래서 $\text{단가} \times \text{수량} \times (1 - \text{할인율})$ 이라는 계산을 할 수 있습니다. 할인율이 10%라면 1-할인율은 90%만 받는다는 뜻입니다.

오른쪽의 전체 매출 1,938,489,803원은 이 계산을 모든 주문에 적용한 뒤 더한 값입니다. 계산 자체 보다 순서가 중요합니다. 먼저 표를 붙이고, 빠진 값이 없는지 본 다음, 그때 매출을 계산해 보세요.

groupby는 기준, agg는 계산이다

뭉을 열을 먼저 정하고, 그 안에서 합계·평균·개수를 계산한다.

- groupby는 지역·카테고리 기준을 정한다
- agg는 주문건수·수량·매출 계산이다
- reset_index는 일반 표로 되돌린다

groupby는 같은 것끼리 묶는 도구입니다. 지역별 매출을 보고 싶으면 지역으로 묶고, 지역 안에서 카테고리까지 보고 싶으면 지역과 카테고리 두 기준으로 묶습니다. 사전에서 ㄱ, ㄴ, ㄷ으로 먼저 나누고 그 안에서 다시 단어를 찾는 느낌입니다.

agg는 묶인 덩어리 안에서 무엇을 계산할지 정하는 부분입니다. 주문건수는 몇 건인지 세고, 판매수량은 수량을 더하고, 매출은 금액을 더하고, 평균주문금액은 평균을 냅니다. 저울에 올릴 대상을 먼저 나눈 뒤, 무게를 잴지 개수를 셀지 고르는 단계입니다.

reset_index는 groupby 결과를 다시 평범한 표 모양으로 돌려놓는 일입니다. pandas는 묶은 기준을 특별한 자리인 인덱스에 올려두는 경우가 있는데, 초보 단계에서는 다시 일반 열로 꺼내 두는 편이 정렬하고 비교하기 쉽습니다.

지역×카테고리 매출 순위



결과

서울특별시×디지털이 **210,356,387원**으로 1위다.

이 막대그래프는 지역과 상품 카테고리를 함께 묶었을 때 매출이 큰 조합을 보여줍니다. 지역만 본 것이 아니라 서울특별시의 디지털, 경기도의 디지털처럼 두 기준을 한꺼번에 본 결과입니다.

어디를 보면 될까요? 막대가 가장 긴 항목을 먼저 보시면 됩니다. 서울특별시 디지털이 210,356,387원으로 가장 큼니다. 그다음은 경기도 디지털 188,110,354원입니다. 패션은 서울특별시가 86,206,229원, 경기도가 75,963,357원으로 디지털보다 훨씬 작습니다.

지역×카테고리 매출 순위

이어서

그래서 이 그림은 매출이 지역보다 카테고리에서 더 크게 갈리는지 생각하게 해 줍니다. 상위 두 개가 모두 디지털이라는 점이 보이죠. 다만 이 그래프만으로 원인을 단정하지는 말고, 주문건수나 평균주문금액도 함께 보면서 해석해 봅니다.

피벗은 긴 집계를 펼친다

인자	뜻	엑셀
index	행 기준	행 영역
columns	열 기준	열 영역
values	계산 값	값 영역
aggfunc	계산 방식	합계·평균
fill_value	빈칸 대체	0 표시

지역×카테고리를 한 화면에서 비교한다.

이 표는 pandas의 pivot_table을 엑셀 피벗 테이블 용어와 맞춰 보는 표입니다. 낯선 영어 인자가 나오지만, 엑셀에서 피벗을 만들어 본 적이 있다면 같은 자리에 대응됩니다.

index는 행 기준입니다. 예를 들어 지역을 index에 넣으면 지역 이름이 세로로 내려갑니다. columns는 열 기준입니다. 카테고리를 columns에 넣으면 디지털, 패션 같은 항목이 가로로 펼쳐집니다. values는 실제로 계산할 숫자이고, 여기서는 매출 같은 값이 들어갑니다.

aggfunc는 합계로 볼지 평균으로 볼지 정하는 계산 방식입니다. fill_value는 빈칸이 생겼을 때 무엇으로 채울지 정합니다. 지역×카테고리 조합이 없는 칸을 비워 두면 헛갈리니, 보통 0으로 표시해 비교하기 쉽게 만듭니다.

melt는 넓은 표를 길게 만든다



결과


열 이름이 값으로 바뀌어 필터와 그룹화가 쉬워진다.

왼쪽의 서울 wide 표는 가로로 매우 넓은 표입니다. 행은 452개인데 열이 231개나 있고, 그중 연령·성별을 나타내는 열이 222개입니다. 0세 남자, 1세 남자처럼 분석 기준이 열 이름 안에 숨어 있는 모양입니다.

melt는 이 넓은 열들을 세로로 내려서 긴 표로 바꿉니다. 오른쪽을 보면 행은 100,344개로 늘고 열은 10개로 줄었습니다. 행이 많아진 대신, 표의 의미는 더 단순해집니다. 연령과 성별이 열 이름 속에 박혀 있지 않고, 연령성별이라는 값으로 내려오기 때문입니다.

왜 굳이 길게 만들까요? 필터와 그룹화가 쉬워지기 때문입니다. 예를 들어 여자만 보기, 20대만 보기, 구별 인구를 합치기 같은 작업은 긴 표에서 훨씬 자연스럽습니다. 옷장을 넓게 펼쳐 둔 상태에서 종류별로 다시 바구니에 담는다고 생각해 보세요.

업종별 업소수는 한식이 가장 많다



결과

119,158행은 업종 집계 후 상위 10개로 줄어든다.


이 막대그래프는 서울 음식점 상가업소 119,158행을 업종별 업소수로 줄인 결과입니다. 원본 한 줄 한 줄을 그대로 읽는 대신, 같은 업종끼리 모아서 몇 곳인지 센 그래프입니다.

가장 먼저 볼 곳은 맨 위 막대입니다. 한식이 40,448곳으로 가장 많습니다. 그다음은 커피점/카페 19,703곳, 유흥주점 11,693곳, 분식 10,199곳입니다. 막대 길이가 업소수 차이를 그대로 보여주기 때문에, 한식이 다른 업종보다 훨씬 큰 비중을 차지한다는 점이 바로 보입니다.

업종별 업소수는 한식이 가장 많다 이어서

여기서 배울 습관은 큰 파일을 먼저 줄여서 본다는 것입니다. 119,158행을 화면에 쭉 출력하면 아무것도 보이지 않습니다. 업종별로 묶고 개수를 세면 상위 10개만 봐도 구조가 잡힙니다.

평균 생활인구는 강남구가 1위다



결과

강남구의 평균 생활인구는 **846,650명**이다.

이 그래프는 서울 25개 자치구 중 평균 생활인구가 큰 자치구 상위 10개를 보여줍니다. 생활인구는 주민등록 인구처럼 사는 사람만 세는 개념이 아니라, 일정 시간대에 그 지역에 머무는 사람 규모를 보는 지표입니다.

막대의 맨 위를 보면 강남구가 846,650명으로 1위입니다. 송파구는 760,200명, 서초구는 591,061명입니다. 강서구 552,962명, 영등포구 514,382명도 상위권에 있습니다. 값이 클수록 기간 전체에서 평균적으로 더 많은 사람이 머물렀다는 뜻입니다.

평균 생활인구는 강남구가 1위다 이어서

이 결과를 만들 때는 서울시 전체 합계 행을 빼고 25개 자치구만 남겨야 합니다. 서울시 전체와 자치구를 함께 비교하면 키와 몸무게를 같은 줄에 세워 재는 것처럼 기준이 섞입니다. 같은 단위끼리 비교해야 그래프를 제대로 읽을 수 있습니다.

강남구는 주간 인구가 더 많다



결과

주간 평균 **995,622명**은 야간 평균보다 많다.

이 그래프는 강남구 하나만 놓고 주간, 전체 평균, 야간 생활인구를 비교합니다. 같은 지역 안에서 시간대에 따라 사람이 얼마나 달라지는지 보는 그림입니다.

가장 긴 막대는 평균주간인구 995,622명입니다. 평균생활인구는 846,650명이고, 평균야간인구는 740,184명입니다. 주간 값이 야간 값보다 크다는 것은 낮 시간에 강남구로 들어와 머무는 사람이 많다는 방향으로 읽을 수 있습니다.

강남구는 주간 인구가 더 많다

이어서

다만 그래프 하나만 보고 원인을 확정하지는 않습니다. 업무지구, 상업시설, 교통, 학교 같은 여러 이유가 섞일 수 있습니다. 오늘은 원인 분석보다 자치구별로 묶고, 평균과 최댓값을 정확히 계산하고, 그래프에서 차이를 읽는 연습에 집중해 보세요.

오늘의 미션

미션 1. 서울시 제외

25개 자치구만 남긴다.

미션 2. 자치구별 집계

관측일수와 평균·최대 인구를 계산한다.

미션 3. 1위 확인

강남구 1위와 관측일수 2,992일을 확인한다.

정리

- **merge**는 표를 붙이고 행 수·누락을 확인한다.
- **groupby**와 **agg**는 기준별 요약표를 만든다.
- **pivot_table**은 펼치고 **melt**는 세로로 내린다.

다음 차시: 집계표를 바탕으로 해석과 시각화로 이어진다.