

S13 · PART 04 · 파이썬 · 난이도 4

그룹화·집계·재구조화

여러 표에 흩어진 정보를 붙이고, 여러 행을 요약표와 long 데이터로 바꾸는 방법을 익힌다.

오늘 끝나면 할 수 있는 것

- 01 `groupby()`로 두 개 이상의 기준 열을 묶고 여러 집계값을 한 번에 계산한다.
- 02 `merge()`를 엑셀의 VLOOKUP 또는 XLOOKUP과 연결해 이해하고, 병합 후 누락값을 확인한다.
- 03 `pivot_table()`로 행과 열 기준이 모두 있는 요약표를 만든다.
- 04 `melt()`로 가로로 넓은 wide 데이터를 세로로 긴 long 데이터로 바꾼다.
- 05 수만 행 이상의 실데이터를 먼저 필터링하거나 집계해 줄인다.

오늘 다루는 데이터의 규모

오늘 다루는 데이터의 규모

데이터	실제 행 수	실제 열 수	수업에서 쓰는 역할
orders.csv	20,000	6	주문일, 고객ID, 상품ID, 수량, 할인율을 다룬다.
customers.csv	3,000	7	고객 성별, 나이, 지역, 등급을 붙인다.
products.csv	200	5	상품명, 카테고리, 단가, 원가를 붙인다.
seoul_commercial_food_stores_202109_github.csv	119,158	13	서울 음식점 업종을 집계한다.
mois_legal_dong_gender_age_population_20260531.csv	18,623	231	wide 형태의 연령·성별 인구 데이터를 바꾼다.
seoul_living_population_gu_daily.csv	77,792	15	자치구별 생활 인구 일별 데이

핵심 개념 1

merge는 pandas의 VLOOKUP이다

주문 표에는 고객 지역과 상품 단가가 없으므로 customer_id와 product_id를 기준으로 고객 표와 상품 표를 붙인다.

- how="left"는 주문표의 20,000행을 기준으로 유지한다.
- 병합 후 결과는 20,000행, 17열이다.
- 병합 뒤 region, category, price 누락값이 모두 0개인지 확인한다.

매출은 병합 뒤 계산한다

orders.csv에는 매출 컬럼이 없다. 단가는 상품 표에서 오고, 수량과 할인율은 주문 표에서 오므로 병합한 뒤 계산한다.

- 매출은 단가에 수량을 곱하고 할인율을 뺀 비율을 다시 곱해 계산한다.
- 전체 매출 합계는 1,938,489,803이다.
- 엑셀에서 VLOOKUP으로 단가를 가져온 뒤 수식을 만드는 흐름과 같다.

groupby는 기준을 정하고 agg는 계산을 정한다

groupby(["region", "category"])는 지역별로 나눈 뒤 카테고리별로 다시 나누는 뜻이다.

- 주문건수는 order_id의 고유 개수를 센다.
- 판매수량은 qty 합계로 계산한다.
- 매출합계는 sales 합계로 계산한다.
- 평균주문금액은 sales 평균으로 계산한다.

지역×카테고리 집계 상위 결과

REGION	CATEGORY	주문건수	판매수량	매출합계	평균주문금액
서울특별시	디지털	612	658	210,356,387	343,720
경기도	디지털	514	565	188,110,354	365,973
서울특별시	패션	990	1,442	86,206,229	87,077
경기도	패션	884	1,292	75,963,357	85,931

매출합계 기준으로 내림차순 정렬한 대표 결과다.

pivot_table은 교차표로 펼친다

인자	뜻	엑셀 피벗과 비교
index	행 기준이다.	행 영역이다.
columns	열 기준이다.	열 영역이다.
values	계산할 값이다.	값 영역이다.
aggfunc	계산 방법이다.	합계, 평균, 개수다.
fill_value	빈 칸 대체값이다.	빈 셀에 0을 표시한다.

margins=True는 합계 행과 합계 열을 만든다.

melt는 넓은 표를 긴 표로 바꾼다

인구 파일은 18,623행, 231열이다. 0세남자, 1세남자처럼 열 이름에 들어 있던 정보를 연령성별 값으로 내린다.

- 수업에서는 서울특별시 452행만 먼저 고른다.
- melt 대상 연령·성별 열은 222개다.
- 서울특별시 long 데이터는 100,344행, 10열이 된다.
- 연령성별에서 성별과 연령을 다시 분리하면 이후 분석이 쉬워진다.

큰 파일은 먼저 줄이고 본다

서울 음식점 상가업소 파일은 119,158행이고 생활인구 파일은 77,792행이다. 원자료를 그대로 많이 출력하거나 바로 그래프로 그리면 이해가 흐려진다.

- 행수와 열 이름을 먼저 확인한다.
- 필요한 열만 고른다.
- 필요한 지역이나 기간만 필터링한다.
- groupby로 먼저 요약한다.
- 요약표를 보고 해석하거나 시각화한다.

오늘의 미션

미션 1. 생활인구 파일 준비

seoul_living_population_gu_daily.csv를 읽고 기준일ID를 날짜로 바꾼다.

미션 2. 자치구 요약표 만들기

서울시 전체 합계 행을 제외하고 25개 자치구별 관측일수, 평균 생활인구, 평균 주간인구, 평균 야간인구, 최대 생활인구를 계산한다.

미션 3. 완료 확인

평균생활인구 기준으로 내림차순 정렬하고, 1위가 강남구이며 강남구 관측일수가 2,992일임을 확인한다.

정리

- merge는 주문표에 없는 고객 지역과 상품 단가를 키 열로 붙이는 방법이다.
- groupby와 agg는 어떤 기준으로 묶고 무엇을 계산할지 분리해 적는 방법이다.
- pivot_table은 지역×카테고리 같은 교차표를 만들고, melt는 wide 데이터를 long 데이터로 바꾼다.
- 큰 공공데이터는 원본을 그대로 보지 말고 필요한 범위로 줄인 뒤 요약한다.

다음 차시는 S14 시각화 실전에서 pandas로 정리한 데이터를 matplotlib과 seaborn 그래프로 바꾸는 흐름을 다룬다.