

시각화 실전: matplotlib·seaborn, 한글폰트, BI 핸드오프

pandas로 정리한 데이터를 질문에 맞는 그래프로 만들고, 한글폰트를 설정한 뒤 차트용 집계 결과를 CSV로 저장해 BI로 넘긴다.

오늘 끝나면 할 수 있는 것

- 01 한글폰트를 설정하고 `axes.unicode_minus=False`가 필요한 이유를 설명한다.
- 02 숫자 분포를 히스토그램과 박스플롯으로 확인한다.
- 03 두 숫자 변수의 관계를 산점도와 추세선으로 표현하고 상관계수를 보조 정보로 해석한다.
- 04 대용량 데이터를 먼저 집계한 뒤 히트맵이나 라인차트로 시각화한다.
- 05 차트에 사용한 정제·집계 결과를 `to_csv()`로 저장해 BI 도구에 넘긴다.

차트는 질문에 답하도록 표를 줄이는 일이다

파이썬 시각화는 표를 선택한 뒤 차트 종류를 고르는 작업에서 멈추지 않는다. 무엇을 알고 싶은지 정하고, 필요한 열만 고른 뒤, 큰 데이터는 필터링하거나 집계해 차트에 맞는 크기로 줄인다.

- 지하철 원본 199,424행은 그대로 그리지 않고 승차 행만 남긴다.
- 역별·시간대별 합계로 줄인 뒤 총 승차 상위 10개 역만 히트맵에 사용한다.
- 히트맵 집계 결과는 상위 10개 역 × 20개 시간대 = 200행이다.

한글폰트 설정은 차트의 전처리다

한글 CSV를 잘 읽었더라도 그래프 제목과 축 글자가 깨질 수 있다. 이때는 데이터 오류가 아니라 matplotlib이 한글 글꼴을 찾지 못한 상태일 수 있다.

- `font.family`는 한글을 표시할 글꼴을 정한다.
- `axes.unicode_minus=False`는 음수 부호가 네모로 깨지는 문제를 줄인다.
- 수강생 환경에서는 `NanumGothic` 또는 `NanumGothicCoding`이 선택되는지 확인한다.

오늘 다루는 데이터와 시각화 역할

데이터	확인값	수업에서 쓰는 역할
seoulmetro_daily_hourly_2025.csv	199,424행, 26열	승차 기준 역별×시간대 히트맵
molit_aprt_sale_seoul_gangnam_2024.csv	3,754행, 20열	거래금액 분포, 면적구간 박스플롯, 면적-가격 산점도
fred_korea_cpi_all_items_monthly.csv	767행, 2열	월별 CPI 시계열
cafe_sales_clean.csv	10,424행, 12 열	미션용 월별 매출 추세

행수와 열수는 python3와 pandas 3.0.3으로 실제 파일을 열어 확인한 값이다.

분포는 히스토그램과 박스플롯으로 본다

강남구 아파트 실거래 데이터는 거래금액을 숫자로 바꾼 뒤 차트용 억원 단위를 만든다. 히스토그램은 어느 가격대 거래가 많은지 보고, 박스플롯은 면적구간별 중앙값과 퍼짐을 함께 본다.

- 거래금액(만원)은 쉼표가 들어간 문자열이므로 숫자형 거래금액_만원으로 변환한다.
- 면적구간은 40m^2 이하, $40\text{-}60\text{m}^2$, $60\text{-}85\text{m}^2$, $85\text{-}120\text{m}^2$, 120m^2 초과로 나눈다.
- 박스플롯은 엑셀 피벗에서 그룹별 평균만 볼 때보다 분포 차이까지 함께 읽게 한다.

관계와 시간 흐름은 차트 모양이 다르다

산점도는 한 행을 점 하나로 표현해 두 숫자 사이의 관계를 본다. 라인차트는 시간 순서가 있는 데이터에서 값의 흐름을 본다.

- 강남구 아파트 데이터의 전용면적과 거래금액 상관계수는 $r = 0.806$ 으로 강한 양의 상관이다.
- 상관계수와 추세선은 관계를 요약하지만 원인을 증명하지는 않는다.
- FRED CPI는 원본 767행 중 2000년 이후 287행만 사용해 월별 라인차트를 만든다.

**“그래프는 표를 예쁘게 꾸미는 일이 아니라
질문에 답하는 일이다.”**

S14 강사대본

오늘의 미션

데이터 준비

cafe_sales_clean.csv를 읽고 date를 날짜형으로 변환한다.

월별 집계와 라인차트

월별 amount 합계를 계산하고, monthly_sales 6행 표와 월별 매출 라인차트를 만든다.

BI 핸드오프 저장

s14_monthly_sales.csv와 s14_monthly_sales_trend.png를 저장하고, 6월 16,816,500원이 가장 높고 2월 13,157,000원이 가장 낮은지 확인한다.

정리

- 한글 차트가 깨지면 데이터가 아니라 matplotlib 글꼴 설정을 먼저 확인한다.
- 큰 데이터는 원본을 바로 그리지 않고 질문에 맞게 필터링하거나 집계한다.
- 히스토그램은 분포, 박스플롯은 그룹별 퍼짐, 산점도는 두 숫자의 관계, 라인 차트는 시간 흐름에 쓴다.
- BI로 넘길 때는 차트에 쓴 정제·집계 결과를 to_csv()로 저장할 수 있다.

다음 차시 — Power BI를 설치 또는 실행하고, 정제된 카페 매출 CSV를 불러와 첫 차트를 만든다.